

经济计量方法导论

第一讲 概述

薛薇

明德主楼：1013

xuewei@ruc.edu.cn

说在前面的事情

- **计量经济学**: 依照经济理论的框架, 以数学和统计为工具, 基于收集到的数据, 从实证角度出发, 估计经济现象间的数量关系以进行理论验证
 - 特点: **理论经济、数量经济、数理统计的交叉研究领域**
 - **理论经济**: 从定性角度提出各种经济理论的假说
 - 例: 微观经济理论指出, 其他条件不变下, 商品价格的下降会带来需求量的增加。一般不研究它们间的数量变化关系
 - **数量经济**: 在理论经济研究的基础上, 通过数学形式研究经济数量关系及其变化规律
 - 例: 如上例, 一般不考虑经验方程的参数估计方法等问题
 - **数理统计**: 以概率论为基础。但经济数据一般以观测数据为基础, 许多数理统计方法在非实验数据的应用中会丧失原有的随机假设

说在前面的事情

- 计量经济学是一门交叉而独立的学科
 - 本课程侧重：基础计量方法的讨论+各类数据+软件实现
- 教材
 - 伍德里奇，《计量经济学导论：现代观点（第六版）》，人大出版社
 - 教材特色：注重公式背后的理论含义；内容丰富（650多页，不全讲）
 - 授课思路：在教材的基础上综合成几个主题
 - 补充读物：伍德里奇，《横截面与面板数据的计量经济分析》
- 成绩和考核方式
 - 平时成绩（平时作业（60%）+期中考试（40%））：60%
 - 期末考核方式：课程论文，期末成绩：40%

主要内容

- 什么是经济计量研究
- 经济计量研究的一般思路
- 经济计量研究的数据对象
- 软件工具

什么是经济计量研究

- 通过收集和研究非实验数据，利用统计方法，对经济学(也包括社会学、管理学)等领域的理论模型进行验证
- 理解1：对领域的理论模型进行验证
 - 以实证分析的方式，在理论假设框架下，利用数据检验理论或某种关系是否成立
 - 例：微观经济理论指出，其他条件不变下某商品价格的下降会带来其需求量的增加
 - 例：失业率对工资增长率的影响(菲利普斯曲线)：失业率上升时，货币工资增长率下降；失业率下降时，货币工资增长率上升
 - 以实证分析的方式，依据常规经验进行实证研究
 - 例：教育回报率问题的研究：受教育程度对工资收入的影响

■ 理解1：对领域的理论模型进行验证

■ 目的：发现因果关联关系，估计因果效应

The goal of most empirical studies in economics and other social sciences is to determine whether a change in one variable, say w , causes a change in another variable, say y .

■ 例如：For example, does having another year of education cause an increase in monthly salary?


Does reducing class size cause an improvement in student performance?

■ 注意：不能混淆相关和因果

■ 相关关系 (Correlation) 统计学术语 (一般指线性相关), 计量中使用关联 (association)

■ 不是所有的关联都是因果关联 (causal association)

■ 例：



- 穿鞋睡觉和睡醒后头疼之间存在关联但非完全因果关联
- 存在公共原因 (common cause)：睡前饮酒 (干扰因子 confounder 或潜在变量 lurking variable)，导致出现干扰性关联




Figure 1.4: Causal structure, where drinking the night before is a common cause of sleeping with shoes on and of waking up with a headaches.

■ 理解1：对领域的理论模型进行验证

- 因果关联研究的前提：依据**理论研究成果**，基于**合理**的事物间的**因果关系结构**

- 不同因果结构下的研究结论可能是不同的

- 例如：不同处方 (A便宜B昂贵) 下流感的死亡率数据

		Condition		
Treatment		Mild	Severe	Total
	A	15% (210/1400)	30% (30/100)	16% (240/1500)
	B	10% (5/50)	20% (100/500)	19% (105/550)

- 辛普森悖论，从数据角度分析原因：
 - 不同处方下病人分布不均匀性
 - A便宜(占比73%(=1500/(1500+550)))
 - A好可能与Mild占比高有关

- 如何基于数据选择处方，可能会因不同的因果关系结构得到不同结论
结构1中：C是T和Y的公共原因, B好

- 应在**相同C**下考察T和Y的关系: B好
- 若忽略结构关系，基于T独立于C：A好
 - 选A：若**叠加**(Mild $\rightarrow$ $\downarrow$ Y)，A好
 - 选B：若叠加(Severe $\rightarrow$ $\uparrow$ Y)，B不好A好

- 结构2中：T是C和Y的公共原因, A好
 - 选A(便宜)：(Mild叠加Mild $\rightarrow$ $\downarrow$ Y) $\rightarrow$ A好
 - 选B(昂贵)：(Mild $\rightarrow$ Severe $\rightarrow$ $\uparrow$ Y) $\rightarrow$ B不好A好
 - 本例中该结构不合理




Figure 1.1: Causal structure of scenario 1, where condition C is a common cause of treatment T and mortality Y. Given this causal structure, treatment B is preferable.




Figure 1.2: Causal structure of scenario 2, where treatment T is a cause of condition C. Given this causal structure, treatment A is preferable.

■ 理解1：对领域的理论模型进行验证

■ 如何估计因果效应

we should use ideas from probability to formalize the sense in which a change in w causes a change in y .

■ 从对 y 的条件期望角度研究

- 满足其他条件相同 (ceteris paribus): 其他因素不变

$$E(y | w, \mathbf{c}) \quad \mathbf{c} \text{ 为控制因素}$$

- 例:商品价格变化对需求量的影响, 要求收入、其他商品价格和個人偏好等相同
- 例:受教育程度对工资的影响, 要求工龄、能力、性别等相同

■ 其他条件相同下估计: $\partial E(y | w, \mathbf{c}) / \partial w$ 称为偏效应 partial effect

- 控制其他因素不变是估计因果效应的关键性前提
- 本课程重点讨论如何通过回归模型估计因果效应!

什么是经济计量研究

- 理解2：实验数据和非实验数据 (noexperimental data)
 - 实验数据在人为**控制**下获得的数据
 - 例：粮食亩产量和品种，控制施肥量、土质等因素
 - 例：减肥茶和减肥效果，控制运动时间、体质、生活习惯等因素
 - 独立样本、配对样本(单一实验组)
 - 例：药物研究的**随机双盲式实验**
 - 实验可通过**控制**以最大限度地减少其他因素的影响，保证其他因素不变
 - 问：分析吸烟(雾霾)与患肺癌的关系，可否采用实验数据？

什么是经济计量研究

- 理解2：实验数据和非实验数据
 - 非实验数据指未对个人、企业或经济系统中的某些部分加以控制所得到的数据。非实验数据也称为观测数据，研究者只是被动搜集数据
 - 例：吸烟对肺癌的影响
 - 例：受教育程度对工资影响

什么是经济计量研究

- 对于非实验数据，保证其他因素不变较为复杂

- 例：

$$E(wage | educ, exper, abil) \quad \mathbf{c} = (exper, abil)$$

exper is years of workforce experience, and *abil* is innate ability.

- 可测量因素的因素：*exper*
 - 不可测量的因素：*abil*

- 例：研究到课率 (*attend*) 对期末成绩 (*score*) 的因果效应

$$E(score | attend, SAT, priGPA)$$

- 还以其他未列出的因素：兴趣，遗漏因素
 - 理论研究成果可帮助减少遗漏因素
 - 仍存在其他问题：能否较好地度量 *wage* 和 *exper*，等等
 - 以上决定了计量研究并非简单的回归分析！

经济计量研究的一般思路

- 第一，构造经济模型 (economic model)
 - 经济模型：在**理论经济**研究的基础上，通过具有明确函数形式的数学方程来定量描述经济关系
 - 通常需要深厚的理论经济基础，需经济学家和数量经济家的合作
 - 例：凯恩斯的边际消费倾向理论：平均而言，人们倾向于随他们收入的增加而增加其消费，但消费增加比不上收入增加的那么多
 - $y = f(x)$ ，表示消费和收入间的关系

$$y = \beta_1 + \beta_2 x \quad (0 < \beta_2 < 1)$$


经济计量研究的一般思路

■ 第一，构造经济模型 (economic model)

■ 例：失业-工资的菲利普斯曲线

- 失业率上升，货币工资增长率下降 (甚至是负增长)；失业率下降，货币工资增长率上升

- $y = f(x)$ ：倒数关系 $y = \beta_0 + \beta_1 \frac{1}{x}$
 - 特点：随着 x 无限增大， $\beta_1 \frac{1}{x}$ 趋于 0， y 趋于渐近于 β_0



- 失业率低于自然失业率时，失业率单位变动引起的工资增长率的变动要大于高于自然失业率水平时引起的工资增长率的变动

经济计量研究的一般思路

- 第一，构造经济模型 (economic model)
 - 例：生产模型描述产值与物质资本、人力资本投入之间的数量关系
 - 生产模型： $y = f(K, H)$
 - 道格拉斯生产函数（产值与物质、人力资本投入关系的经济模型）

$$y = \beta_1 K^{\beta_2} H^{\beta_3}$$

β_2 、 β_3 分别为产值对物质资本、人力资本投入的弹性系数

- 经济模型也可以为非规范的常规经验模型
 - 例： $wage = f(educ, exper, training)$ ，描述工资与受教育年份、工龄、岗位培训时间之间的关系

$$wage = \beta_1 + \beta_2 edu + \beta_3 exper + \beta_4 training$$

经济计量研究的一般思路

- 第二，构造**计量模型** (econometric model)
 - 计量模型：通过数理方程描述经济关系间的非确定性

- 例：凯恩斯消费理论

$$y = \beta_1 + \beta_2 x + u$$

- 例：道格拉斯生产函数

$$y = \beta_1 K^{\beta_2} H^{\beta_3} e^u$$

- 例：工资问题

$$wage = \beta_0 + \beta_1 educ + \beta_2 exper + \beta_3 training + u$$

- u 为干扰或误差项，表示模型中未包含的其他因素的影响，是一个随机变量——解决理论不完备问题！


经济计量研究的一般思路

- 第三，搜集数据
- 第四，估计计量模型中的参数
 - 例：OLS估计
- 第五，计量模型的验证
 - 统计检验
 - 经济意义的验证：所得模型是否是经济关系的现实表示，是否与待检验的理论期望值相一致，等等
 - 例：凯恩斯消费理论中的边际消费倾向小于1 $y = \beta_1 + \beta_2 x \ (0 < \beta_2 < 1)$
- 第六，预测和控制
- **问题：**为什么计量模型一般都是形式较为简单的**回归模型**？

- 计量研究注重可解释性，而非预测精度
- 例如：有关小时工资的分析

- 数据：美国CPS (Current Population Survey)
数据，观测数据

- WAGE: average hourly earnings;
- EDUC: years of education;
- EXPER: years potential experience;
- TENURE: years with current employer;
- SMSA: standard metropolitan statistical area;
- FEMALE: 1 if female;
- NONWHITE: 1 if nonwhite




•分析思路

- 建立预测小时工资的**预测模型**


- 基于预测模型进行**统计推断**——分析影响小时工资的影响关系(正向/反向, 线性/非线性)

- 如何做: 估计 Y 与 X 的真实关系: $Y = f(X) + \epsilon$.

- f 刻画了 X 对 y 的系统性关系(未知)
- $E(\epsilon) = 0$, 且 ϵ 与 X 不相关



右图为真实关系, 左图为观测数据



增加考虑工作资历



- 核心任务: 估计 f

如何估计 f

- 目标：找到一个 $\hat{f}$ ，对任意观测 (X, Y) ，有： $Y \approx \hat{f}(X)$
- 通常的做法
 - 首先，假设函数 f 的形式为一般线性回归模型：
 - 然后，训练模型：

$$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p.$$

$$Y \approx \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p.$$



归结为参数的估计问题

$$\text{income} \approx \beta_0 + \beta_1 \times \text{education} + \beta_2 \times \text{seniority}.$$

- 方法的优势：简单方便；容易解释
- 方法的劣势： f 假设(如线性假设)可能是不正确的，预测精度不高
 - 改进：找到更灵活(复杂)的模型，降低预测误差
 - 改善模型 f 仍无法解决的问题：
 - 预测误差的来源：可降误差(reducible error)+非可降误差(irreducible error)

$$Y = f(X) + \epsilon.$$

$E(\epsilon) = 0$ ，且 ϵ 与 X 不相关


$$\hat{Y} = \hat{f}(X)$$

mean squared error
(MSE)

$$E(Y - \hat{Y})^2 = E[f(X) + \epsilon - \hat{f}(X)]^2$$

假设 X 是确定性的：
$$= \underbrace{[f(X) - \hat{f}(X)]^2}_{\text{Reducible}} + \underbrace{\text{Var}(\epsilon)}_{\text{Irreducible}},$$

- 改善 $\hat{f}$ ，可减少可降误差
- 但 $\text{Var}(\epsilon)$ 导致的非可降误差通常不等于0
- 复杂的模型还会出现过拟合(overfitting)
 - 黑色是真实关系；橙→蓝→绿灵活度增加，拟合数据精度增加，但绿色更远离真实关系



经济计量研究的一般思路

- 计量研究聚焦验证性和因果效应度量

- 需关注：模型设置的合理性，模型的理论基础至关重要

- 例：凯恩斯消费理论 $y = \beta_1 + \beta_2 x + u$

- 例：道格拉斯生产函数 $y = \beta_1 K^{\beta_2} H^{\beta_3} e^u$

- 例：工资问题

$$E(\text{wage} \mid \text{educ}, \text{exper}, \text{abil})$$

- 需关注：因果效应度量

- 模型参数是否易于解释，取决于模型的形式(形式简单的回归模型较好)

- 模型参数估计是否是因果效应的良好估计，强调参数估计的性质

经济计量研究的数据对象

- 横截面数据 (Cross-sectional data)
 - 在给定某时点下，由个人、家庭、企业、城市、国家等一系列单位所构成的数据集
 - 例：工资和个人特征的数据 (wage1)

<i>obsno</i>	<i>wage</i>	<i>educ</i>	<i>exper</i>	<i>female</i>	<i>married</i>
1	3.10	11	2	1	0
2	3.24	12	22	1	1
3	3.00	11	2	0	0
4	6.00	8	44	0	1
5	5.30	12	7	0	1
.	.	.	.	.	.

经济计量研究的数据对象

- 横截面数据 (Cross-sectional data) 的特点
 - 在满足随机抽样假设下研究 $E(y|w, c)$,
 - 依据理论框架确定总体模型
 - 例: $wage = \beta_0 + \beta_1 educ + \beta_2 exper + \beta_3 training + u$
 - 数据是以随机方式从总体模型中抽取的, 满足独立同分布 (Independent, Identically Distributed, IID)

$$wage_i = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 training_i + u_i$$

- 忽略数据集中各观测数据收集时的微小时间差异, 视为是近似相同时点上的横截面维度上的随机抽样
- 解释变量和被解释变量均视为随机变量, 不使用固定解释变量

经济计量研究的数据对象

- 横截面数据 (Cross-sectional data) 的特点
 - 随机抽样假设有时可能是不满足的
 - 例：空间相关导致的非独立：核心区域的辐射作用
 - 一般研究忽略空间相关性，或选择恰当的估计方法
 - 例：整群抽样导致的非独立：同班同学的群内相似性
 - 群内相关性
 - 例：研究收入和消费关系时，只观测到了低收入家庭
 - 选择性样本

经济计量研究的数据对象

- 时间序列数据 (time series data)
 - 由对一个或几个变量不同时间上的观测值，按先后顺序所构成的数据集
 - 例：股票价格、消费者价格指数、汽车销售量
- 特点：
 - 时间序列数据的时间频率 (data frequency, 天、周、月、季、年)，导致数据可能表现出很强的季节性、周期性等，是时序数据分析的重要方面
 - 很少能够假设经济数据的观测独立于时间，使得时间序列数据的建模较截面数据困难

经济计量研究的数据对象

- 混和横截面数据 (pooled cross section)
 - 把不同时点的横截面数据混合起来，数据既有横截面数据，又有时间序列数据的特点
 - 例：财产税下调前后的商品住宅销售数据
 - 特点：
 - 数据的前后排列顺序不重要
 - 有关于时点的标志变量
 - 与截面数据类似但一般独立不同分布
 - 应用：
 - 扩大样本量
 - 分析一项新政的影响

obsno	year	hprice	proptax	sqrft	bdrms	bthrms
1	1993	85500	42	1600	3	2.0
2	1993	67300	36	1440	3	2.5
3	1993	134000	38	2000	4	2.5
.	.	.	.	.	.	.
.	.	.	.	.	.	.
.	.	.	.	.	.	.
250	1993	243600	41	2600	4	3.0
251	1995	65000	16	1250	2	1.0
252	1995	182400	20	2200	4	2.0
253	1995	97500	15	1540	3	2.0
.	.	.	.	.	.	.
.	.	.	.	.	.	.
.	.	.	.	.	.	.
520	1995	57200	16	1100	2	1.5

250个调查数据

270个调查数据

- 面板数据 (panel data): 也称纵向数据 (longitudinal data), 由每个截面单位的一个或多个时间序列数据组成

- 所有截面单位在不同时间上重复观测的结果

- 例: 城市犯罪统计的两年面板数据

<i>obsno</i>	<i>city</i>	<i>year</i>	<i>murders</i>	<i>population</i>	<i>unem</i>	<i>police</i>
1	1	1986	5	350000	8.7	440
2	1	1990	8	359200	7.2	471
3	2	1986	2	64300	5.4	75
4	2	1990	1	65100	5.5	75
.	.	.	.	.	.	.

- 特点:

- 截面单位的排列前后顺序随意
- 有关于截面单位和时间的标志变量
- 截面单位具有时序相关性

- 应用: 如两期面板数据更适合分析一项新政的影响

- 平衡面板数据 (balanced panel data)

- N个截面单位中的每一个都有相同的T期数据
- 一般主要研究平衡面板数据

- 非平衡面板数据 (unbalanced panel data)

- N个截面单位中某些时期的观测值存在缺失


软件工具：R语言实现

- R的AER包：Applied Econometrics with R
- R温习示例：工资影响因素分析起步

```
Data<-read.table(file="wage1.txt",header=TRUE,sep=" ")  
###WAGE:average hourly earnings; EDUC:years of education  
#EXPER:years potential experience; TENURE:years with current employer  
#SMSA:standard metropolitan statistical area  
#FEMALE: =1 if female; NONWHITE: =1 if nonwhite
```

```
Data$FEMALE<-as.factor(Data$FEMALE)  
Data$NONWHITE<-as.factor(Data$NONWHITE)  
Data$SMSA<-as.factor(Data$SMSA)
```

```
par(mfrow=c(2,3))  
plot(WAGE~EDUC,data=Data)  
plot(WAGE~EXPER,data=Data)  
plot(WAGE~TENURE,data=Data)  
plot(WAGE~SMSA,data=Data)  
plot(WAGE~FEMALE,data=Data)  
plot(WAGE~NONWHITE,data=Data)
```




软件工具：Stata实现

- Stata的数据.dta

- EXCEL数据的导入

- 生成新变量...



数据编辑器(编辑) - [wage1]

文件(F) 编辑(E) 视图(V) 数据(D) 工具(T)

WAGE[1] 3.1

	WAGE	TENURE	SMSA	EDUC	EXPER	FEMALE	NONWHITE
1	3.1	0	1	11	2	1	0
2	3.24	2	1	12	22	1	0
3	3	0	0	11	2	0	0
4	6	28	1	8	44	0	0
5	5.3	2	0	12	7	0	0
6	8.75	8	1	16	9	0	0
7	11.25	7	1	18	15	0	0
8	5	3	1	12	5	1	0
9	3.6	4	1	12	26	1	0
10	18.18	21	1	17	22	0	0
11	6.25	2	1	16	8	1	0
12	8.13	0	1	13	3	1	0
13	8.77	0	1	12	15	0	0

变量窗口

过滤变量



名称	标签	类型	格式	值标签
☒ WAGE	WAGE	double	%10.0g	
☒ TENURE	TENURE	byte	%10.0g	
☒ SMSA	SMSA	byte	%10.0g	
☒ EDUC	EDUC	byte	%10.0g	
☒ EXPER	EXPER	byte	%10.0g	
☒ FEMALE	FEMALE	byte	%10.0g	
☒ NONWHITE	NONWHITE	byte	%10.0g	

- 基本描述统计：描述数据→摘要统计量


```
. summarize WAGE EDUC EXPER
```

Variable	Obs	Mean	Std. Dev.	Min	Max
WAGE	526	5.896103	3.693086	.53	24.98
EDUC	526	12.56274	2.769022	0	18
EXPER	526	17.01711	13.57216	1	51


■ Stata的基本图形展示




核密度估计图






向日葵图



局部加权回归



■ Stata的.do文件



• 计量经济学论文写作框架：
升级对家庭碳排放的影响为例

