

第七讲

独立混合横截面数据、 面板数据的经济计量方法



独立混合横截面数据的 回归建模

独立混合横截面数据概述

- 把不同时点的横截面数据混合起来，数据既有横截面数据，又有时间序列数据的特点
 - 例：房产税下调前后的商品住宅销售数据
- 同一时点内数据(截面数据)的前后排列顺序不重要；需有关于时点的标志变量
- 观测在截面和时序上均相互独立

obsno	year	hprice	proptax	sqrft	bdrms	bthrms
1	1993	85500	42	1600	3	2.0
2	1993	67300	36	1440	3	2.5
3	1993	134000	38	2000	4	2.5
.	.	.	.	.	.	.
.	.	.	.	.	.	.
.	.	.	.	.	.	.
250	1993	243600	41	2600	4	3.0
251	1995	65000	16	1250	2	1.0
252	1995	182400	20	2200	4	2.0
253	1995	97500	15	1540	3	2.0
.	.	.	.	.	.	.
.	.	.	.	.	.	.
.	.	.	.	.	.	.
520	1995	57200	16	1100	2	1.5

250个调查数据

270个调查数据

独立混合横截面数据的应用

- 能够有效扩大样本量，在此基础上更有效地研究经济现象之间的因果效应
 - 采用混合OLS(Pooled OLS)。前提：变量间的关系不随时间推移而改变
- 政策研究(重点)
 - 将不同时点的样本数据看做来自不同时点的分布可能不同的总体的多组独立随机样本
 - 建模重点：检验样本是否来自同一个总体，不同时点上因变量和自变量间的关系是否存在跨时结构性变化，可能表现在：
 - 截距的差异：因变量平均水平的跨时差异性
 - 斜率的差异：自变量对因变量影响效应的跨时差异性
 - 策略：引入时间虚拟自变量

独立混合横截面回归：跨时结构性变化研究

- 例13.3：1978年有计划将选址建立垃圾焚化炉，1981年开始动工。基于价格数据(kielmc.xls1)分析垃圾焚化炉选址对商品房价格的影响

- 对1981年建模： $rprice = \gamma_0 + \gamma_1 nearinc + u$

虚拟自变量，1表示靠近焚化炉

	RPRICE	Y81	NEARINC
1	60000	0	1
2	40000	0	1
3	34000	0	1
4	63900	0	1
5	44000	0	1
6	46000	0	1
7	56000	0	1
8	38500	0	1
9	60500	0	1
10	55000	0	1
11	39000	0	1
12	41000	0	1
13	50900	0	1
14	52000	0	0

. regress RPRICE NEARINC if Y81==1

Source	SS	df	MS
Model	2.7059e+10	1	2.7059e+10
Residual	1.3661e+11	140	975815046
Total	1.6367e+11	141	1.1608e+09

RPRICE	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
NEARINC	-30688.27	5827.709	-5.27	0.000	-42114.68 -19061.86
_cons	101307.5	3093.027	32.75	0.000	95111.45 107503.55

问：基于1981年的分析结果，可否认为垃圾焚化炉的建设拉低了相应区域的住房价格？

答：对比1978年的分析，结论是不一定，只说明是在低价格区域选址

Number of obs = 142
F(1, 140) = 27.73
Prob > F = 0.0000
R-squared = 0.1653
Adj R-squared = 0.1553
Root MSE = 31157.92

. regress RPRICE NEARINC if Y81==0

Source	SS	df	MS	Number of obs	=	179
Model	1.3636e+10	1	1.3636e+10	F(1, 177)	=	15.74
Residual	1.5332e+11	177	866239953	Prob > F	=	0.0001
Total	1.6696e+11	178	937979126	R-squared	=	0.0817
				Adj R-squared	=	0.0765
				Root MSE	=	29432

RPRICE	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
NEARINC	-18824.37	4744.594	-3.97	0.000	-28187.62 -9461.117
_cons	82517.23	2653.79	31.09	0.000	77280.09 87754.37


1978年结果

■ 如何分析焚化炉建设是否可能导致房价降低？

■ 计算： $\hat{\delta}_1 = -30,688.27 - (-18,824.37) = -11,863.9.$

$$\hat{\delta}_1 = (\overline{rprice}_{81,nr} - \overline{rprice}_{81,fr}) - (\overline{rprice}_{78,nr} - \overline{rprice}_{78,fr}),$$

■ 称为**双重差分估计量** (difference-in-difference estimator, DID)



■ 如何分析焚化炉建设是否可能导致房价降低？

$$\hat{\delta}_1 = -30,688.27 - (-18,824.37) = -11,863.9. \quad \hat{\delta}_1 = (\overline{rprice}_{81,nr} - \overline{rprice}_{81,fr}) - (\overline{rprice}_{78,nr} - \overline{rprice}_{78,fr}),$$

- 还需分析双重差分估计量在统计上**是否显著**，所以，引入**时间虚拟变量**
 - 指定基准组：设置年虚拟变量y81 (0:1978; 1:1981)

$$rprice = \beta_0 + \delta_0 y81 + \beta_1 nearinc + \delta_1 y81 \cdot nearinc + u,$$

- β_0 度量了78年远离焚化炉的平均房价
- δ_0 度量了78至81年总体房价的平均变化情况
- β_1 度量了区位效应
- δ_1 是双重差分估计量，度量了两区域房价的平均差价在不同时期的差别(因新建焚化炉所致)

- 结论：垃圾焚化炉对房价平均水平并没有产生显著的拉低作用

. regress RPRICE NEARINC Y81 c.NEARINC#c.Y81

Source	SS	df	MS	Number of obs	=	321
Model	6.1055e+10	3	2.0352e+10	F(3, 317)	=	22.25
Residual	2.8994e+11	317	914632739	Prob > F	=	0.0000
Total	3.5099e+11	320	1.0969e+09	R-squared	=	0.1739
				Adj R-squared	=	0.1661
				Root MSE	=	30243

RPRICE	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
NEARINC	-18824.37	4875.322	-3.86	0.000	-28416.45	-9232.293
Y81	18790.29	4050.065	4.64	0.000	10821.88	26758.69
c.NEARINC#c.Y81	-11863.9	7456.646	-1.59	0.113	-26534.67	2806.867
_cons	82517.23	2726.91	30.26	0.000	77152.1	87882.36

双重差分估计应用：平均处理效应估计

■ 问题的提出

- 例：出国深造是否对未来职业发展产生影响？通常认为出国深造可能更利于未来的职业发展。研究方案：处理组和对照组的对比分析
 - 出国深造同学作为处理组 ($w_i = 1$)；未出国深造同学作为对照组 ($w_i = 0$)，分别收集两组的职业发展评分数据



- 研究中可能出现的问题：因“自我选择”可能会得到不同的结论
 - 例如：出国深造组的职业发展评分低于未出国深造组
 - 原因：处理组和对照组同学的初始条件不完全相同，导致选择性偏差 (selection bias)

■ 研究方案：反事实框架，也称鲁宾因果模型 (Rubin Causal Model, RCM)

■ $y_i = \begin{cases} y_{1i}, w_i = 1 \\ y_{0i}, w_i = 0 \end{cases}$

- w 为处理变量 (决策变量: 1 处理组, 0 对照组)
- y 为感兴趣的结果变量
- 计算处理效应: $y_{1i} - y_{0i}$

■ 可写为:

- 不同个体的处理效应是不同的, 将 (y_{1i}, y_{0i}, w_i) 视为一个随机样本观测
 - 假设: 样本为 IID, 意味着个体决策 w_i 不受其他个体的影响 (排除个体间的社会互动): **个体处理效应稳定性假设**
- $y_{1i} - y_{0i}$ 为随机变量, 故关注: **ATE** $\equiv E(y_{1i} - y_{0i})$
 - 从总体中随机抽取一个个体的期望处理效应, 称为 **平均处理效应** (Average Treatment Effect, ATE)
- 通常还关注: **ATT** $\equiv E(y_{1i} - y_{0i} | w_i = 1)$; **ATU** $\equiv E(y_{1i} - y_{0i} | w_i = 0)$
 - 从 $w = 1$ 的总体中随机抽取一个个体的期望处理效应, 称为 **参与者平均处理效应** (Average Treatment effect on the Treated)
 - 从 $w = 0$ 的总体中随机抽取一个个体的期望处理效应, 称为 **非参与者平均处理效应** (Average Treatment effect on the Untreated)
- 估计中的困难: 无法 “穿越”, 对每个个体不可能同时观测到 y_{1i}, y_{0i}
 - 处理策略: 在 **反事实设置框架** 下进行平均处理效应的双重差分估计

平均处理效应的双重差分估计

- 例：在A、B两省各选取2个企业，并利用其托宾Q值(越大越好)评价企业业绩(税法改革.xlsx)。2014年开始B省进行了税法改革，A省没有进行改革，获得了相关数据如下
 - 研究目标：评价2014年税法改革的效果
 - 研究角度：B省：处理组(受税法改革影响)；A省：对照组(不受税法改革影响)
 - 以2014年为时间节点，可视为两期(2014年前、后)混合横截面数据(忽略企业id和具体年份)

- 描述统计

```
> aggregate(qvalue~province+y2014,FUN=mean,data=Data)
  province y2014 qvalue
1        A      0   5.78
2        B      0   6.78
3        A      1   5.95
4        B      1   7.35
```

- B省处理组(2014年前后的平均Q值)：

$$T_{before} = 6.78, T_{after} = 7.35$$

- A省对照组(2014年前后的平均Q值)：

$$C_{before} = 5.78, C_{after} = 5.95$$

id	year	qValue	tax	y2014	province	id	year	qValue	tax	y2014	province
1	2010	7.00	0	0	B	1	2014	7.60	1	1	B
1	2011	7.02	0	0	B	1	2015	7.50	1	1	B
1	2012	7.04	0	0	B	1	2016	7.60	1	1	B
1	2013	7.06	0	0	B	1	2017	7.70	1	1	B
2	2010	6.50	0	0	B	2	2014	7.20	1	1	B
2	2011	6.52	0	0	B	2	2015	7.10	1	1	B
2	2012	6.54	0	0	B	2	2016	7.10	1	1	B
2	2013	6.56	0	0	B	2	2017	7.00	1	1	B
3	2010	6.00	0	0	A	3	2014	6.20	0	1	A
3	2011	6.02	0	0	A	3	2015	6.20	0	1	A
3	2012	6.04	0	0	A	3	2016	6.20	0	1	A
3	2013	6.06	0	0	A	3	2017	6.20	0	1	A
4	2010	5.50	0	0	A	4	2014	5.70	0	1	A
4	2011	5.52	0	0	A	4	2015	5.70	0	1	A
4	2012	5.54	0	0	A	4	2016	5.70	0	1	A
4	2013	5.56	0	0	A	4	2017	5.70	0	1	A

平均处理效应的双重差分估计

- 从参与者(B省市)平均处理效应角度，评价2014年税法改革的效果研究

- $ATT \equiv E(y_{1i} - y_{0i} | tax_i = 1)$

- $tax_i = w_i$

- B省处理组(2014年前后的平均Q值):

$$T_{before} = 6.78, T_{after} = 7.35$$

- A省对照组(2014年前后的平均Q值):

$$C_{before} = 5.78, C_{after} = 5.95$$

- 两种角度的反事实设置:

反事实设置1

$$ATT1 = T_{after} - T'_{after} = T_{after} - C_{after} = 7.35 - 5.95 = 1.4$$

反事实设置2

$$ATT2 = T_{after} - T'_{after} = T_{after} - T_{before} = 7.35 - 6.78 = 0.57$$

---单重差分法

■ 利用回归实现单重差分法(反事实设置1)

```
> model<-lm(qvalue~province,data=subset(Data,Data$y2014==1))
> summary(model)
```

```
Call:
lm(formula = qvalue ~ province, data = subset(Data, Data$y2014 == 1))
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-0.35  -0.25   0.00   0.25   0.35
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  5.95000    0.09636   61.75  < 2e-16 ***
provinceB    1.40000    0.13628   10.27 6.68e-08 ***
```

```
> aggregate(qvalue~province+y2014,FUN=mean,data=Data)
  province y2014 qvalue
1         A     0   5.78
2         B     0   6.78
3         A     1   5.95
4         B     1   7.35
```

$$ATT1 = T_{after} - T'_{after} = T_{after} - C_{after} = 7.35 - 5.95 = 1.4$$

• 回归模型: $y = \beta_0 + \beta_1 province + u$ A省为参照类 (0:A; 1:B)

$$E(y|province = 1) = \beta_0 + \beta_1 + E(u|province = 1)$$

$$E(y|province = 0) = \beta_0 + E(u|province = 0)$$

$$E(y|province = 1) - E(y|province = 0)$$

$$= \beta_1 + E(u|province = 1) - E(u|province = 0)$$

■ 可见, 一重差分:

■ $ATT1 = 1.4$: 是不同省份的其他因素相同下的估计

■ 不易成立(比如税改地区经济水平(u)高于非税改地区) $\rightarrow 1.4$

■ 处理组和对照组2014后的差分: $T_{after} - C_{after} = \beta_1 + \text{其他随省变化的因素的影响}$

■ 其他随省变化的因素的影响可用处理组和对照组2014前的差分作为估计:

■ 其他随省变化的因素的影响 $= T_{before} - C_{before}$

■ 需要第二重差分: $[T_{after} - C_{after}] - [T_{before} - C_{before}] = \beta_1$

■ 利用回归实现单重差分法(反事实设置2)

```
> model<-lm(qvalue~y2014,data=subset(Data,Data$province=='B'))
> summary(model)
```

```
call:
lm(formula = qvalue ~ y2014, data = subset(Data, Data$province ==
"B"))
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-0.35  -0.25   0.00   0.25   0.35
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  6.78000    0.09655  70.224  < 2e-16 ***
y2014        0.57000    0.13654   4.175  0.000936 ***
---

```

```
> aggregate(qvalue~province+y2014,FUN=mean,data=Data)
  province y2014 qvalue
1         A     0   5.78
2         B     0   6.78
3         A     1   5.95
4         B     1   7.35
```

$$ATT2 = T_{after} - T'_{after} = T_{after} - T_{before} = 7.35 - 6.78 = 0.57$$

• 回归模型: $y = \beta_0 + \beta_1 y2014 + u$

$$E(y|y2014 = 1) = \beta_0 + \beta_1 + E(u|y2014 = 1)$$

$$E(y|y2014 = 0) = \beta_0 + E(u|y2014 = 0)$$

$$E(y|y2014 = 1) - E(y|y2014 = 0)$$

$$= \beta_1 + E(u|y2014 = 1) - E(u|y2014 = 0)$$

■ 可见, 一重差分:

■ $ATT2 = 0.57$: 是2014年前后其他因素不发生变化下的估计

■ 不易成立(比如2014后国家信贷政策放松(u))

■ 处理组在2014前后的差分: $T_{after} - T_{before} = \beta_1 + \text{其他随时间变化的因素的影响}$

■ 其他随时间变化的因素影响可用对照组2014前后的差分作为估计


■ 其他随时间变化的因素的影响 = $C_{after} - C_{before}$

■ 需要第二重差分: $[T_{after} - T_{before}] - [C_{after} - C_{before}] = \beta_1$

■ 双重差分估计: difference-in-difference estimator, DID

$$[T_{after} - C_{after}] - [T_{before} - C_{before}] = \beta_1 \iff [T_{after} - T_{before}] - [C_{after} - C_{before}] = \beta_1$$

事件后两组均值之差-事件前两组均值之差,
该差异可认为是事件所导致的



```
> model<-lm(qvalue~province+y2014+province*y2014,data=Data)
> summary(model)
```

```
Call:
lm(formula = qvalue ~ province + y2014 + province * y2014, data = Data)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-0.35  -0.25   0.00   0.25   0.35
```

```
Coefficients:
(Intercept)      5.78000    0.09562  60.449 < 2e-16 ***
provinceB         1.00000    0.13522   7.395 4.71e-08 ***
y2014             0.17000    0.13522   1.257  0.2191
provinceB:y2014   0.40000    0.19124   2.092  0.0457 *
```

• 回归模型: $y = \alpha_0 + \alpha_1 \text{province} + \alpha_2 y2014 + \alpha_3 \text{province} \cdot y2014 + u$

- α_0 : province = 0, y2014 = 0: C_{before}
- α_1 : province = 1, y2014 = 0: $[T_{before} - C_{before}]$
- α_2 : province = 0, y2014 = 1: $[C_{after} - C_{before}]$
- α_3 : province = 1, y2014 = 1: DID估计且可进行统计检验

```
> aggregate(qvalue~province+y2014,FUN=mean,data=Data)
  province y2014 qvalue
1        A     0   5.78
2        B     0   6.78
3        A     1   5.95
4        B     1   7.35
```

独立混合横截面回归

- 独立混合横截面回归研究跨时结构性变化的问题
 - 基于独立样本的总体均值检验
 - 不同时期的个体不同，存在异质性，模型没有对不同时期下不同个体特征进行控制（默认不变）
- 改进策略
 - 采用配对样本
 - 减肥茶问题研究中的独立样本和配对样本



面板数据的回归建模

什么是面板数据

- 面板数据：由多个截面单位的多个时序组成的数据
 - 例：北京、天津、河北、黑龙江、江苏、浙江2000-2009年的人均GDP(元)和城镇化率(%)
- 面板数据的基本称谓
 - **截面**(时间):T(10)期；**截面单位**(地区):N(6)个
- 面板数据与独立混合截面数据的主要不同
 - 独立混合截面数据由多个时点的独立样本组成
 - 面板数据是对截面单位在不同时期的重复观测，各个截面的数据有配对的特点

	YEAR ↕	GDP ↕	CZHL ↕	PROVINCE ↕
1	2000	22460	77.54	BEIJING
2	2001	25523	78.10	BEIJING
3	2002	28449	79.50	BEIJING
4	2003	32061	79.10	BEIJING
5	2004	41099	78.60	BEIJING
6	2005	45444	83.62	BEIJING
7	2006	50467	84.33	BEIJING
8	2007	58204	84.50	BEIJING
9	2008	63029	84.90	BEIJING
10	2009	68788	85.00	BEIJING
11	2000	17993	71.99	TIANJIN
12	2001	20154	72.08	TIANJIN
13	2002	22380	72.59	TIANJIN
14	2003	26532	72.30	TIANJIN
15	2004	30575	72.15	TIANJIN
16	2005	35783	75.11	TIANJIN
17	2006	41163	75.73	TIANJIN

什么是面板数据

- 简单应用：利用面板数据的配对特点，针对两期面板数据进行政策效果研究
 - 续前例：4个企业的两期 (2014年前和后) 跟踪调查数据：两期面板数据 (T=2, N=4)

id	year	qValue	tax	y2014	province	id	year	qValue	tax	y2014	province
1	2010	7.00	0	0	B	1	2014	7.60	1	1	B
1	2011	7.02	0	0	B	1	2015	7.50	1	1	B
1	2012	7.04	0	0	B	1	2016	7.60	1	1	B
1	2013	7.06	0	0	B	1	2017	7.70	1	1	B
2	2010	6.50	0	0	B	2	2014	7.20	1	1	B
2	2011	6.52	0	0	B	2	2015	7.10	1	1	B
2	2012	6.54	0	0	B	2	2016	7.10	1	1	B
2	2013	6.56	0	0	B	2	2017	7.00	1	1	B
3	2010	6.00	0	0	A	3	2014	6.20	0	1	A
3	2011	6.02	0	0	A	3	2015	6.20	0	1	A
3	2012	6.04	0	0	A	3	2016	6.20	0	1	A
3	2013	6.06	0	0	A	3	2017	6.20	0	1	A
4	2010	5.50	0	0	A	4	2014	5.70	0	1	A
4	2011	5.52	0	0	A	4	2015	5.70	0	1	A
4	2012	5.54	0	0	A	4	2016	5.70	0	1	A
4	2013	5.56	0	0	A	4	2017	5.70	0	1	A

- 分别计算4个企业的两期qValue的均值
- 分析4个企业两期qValue均值的差，在不同省(组/是否税改)的差异是否显著

	id	qValue	province	NewqValue
1	1	7.03	B	7.6
2	2	6.53	B	7.1
3	3	6.03	A	6.2
4	4	5.53	A	5.7

```
lm(formula = (NewqValue - qValue) ~ province, data = NewData)

Residuals:
    1         2         3         4 
1.110e-16 -1.110e-16 -1.849e-32 -1.849e-32 

Coefficients:
              Estimate Std. Error  t value Pr(>|t|)
(Intercept)  1.70e-01   7.85e-17  2.165e+15  <2e-16 ***
provinceB    4.00e-01   1.11e-16  3.603e+15  <2e-16 ***
```

面板数据还有其他更重要的意义！

面板数据的类型

- 平衡面板：任意第 i 个截面单位在任意 t 都有观测；否则称为非平衡面板
- 短面板数据 ($T \ll N$)
 - T 固定, 每个时点上的数据视为来自元素个数趋于 ∞ 的截面单位总体中的随机抽样
 - 有多组配对特征的截面数据
- 长面板数据 ($T \gg N$)
 - N 固定, 每个截面单位数据都有多个 T 趋于 ∞ 的时间序列
 - 时间序列的回归研究需注意平稳弱相关等问题
- 一般面板 ($T \approx N$)：略复杂，教材更倾向于视为短面板

短面板的研究和模型

- 例：基于短面板研究GDP对城镇化率的影响效应
 - 目标：估计GDP对城镇化率的影响效应

- 建立回归模型：

$$y_{it} = \alpha + \mathbf{X}_{it}'\boldsymbol{\beta} + v_{it}, i = 1, \dots, N; t = 1, \dots, T$$

- $\mathbf{X}$ 、 y 、 v 两个下标 it 表示取值随截面单位和时间不同
- 模型体现 $\mathbf{X}$ 随时间(截面)和截面单位不同取值对 y 的影响
- 参数估计：采用OLS估计，得到的估计称为混合OLS估计(Pooled OLS, 总体平均估计量 Population-average estimator)

■ R的面板分析示例：城镇化率的混合OLS估计

	YEAR	GDP	CZHL	PROVINCE
1	2000	22460	77.54	BEIJING
2	2001	25523	78.10	BEIJING
3	2002	28449	79.50	BEIJING
4	2003	32061	79.10	BEIJING
5	2004	41099	78.60	BEIJING
6	2005	45444	83.62	BEIJING
7	2006	50467	84.33	BEIJING
8	2007	58204	84.50	BEIJING
9	2008	63029	84.90	BEIJING
10	2009	68788	85.00	BEIJING
11	2000	17993	71.99	TIANJIN
12	2001	20154	72.08	TIANJIN
13	2002	22380	72.59	TIANJIN
14	2003	26532	72.30	TIANJIN
15	2004	30575	72.15	TIANJIN
16	2005	35783	75.11	TIANJIN
17	2006	41163	75.73	TIANJIN

```
library("plm")
Data<-read.table(file="面板数据示例.txt",header=TRUE,sep=" ")
#PData<-plm.data(Data,index=c("PROVINCE","YEAR")) #指定截面单位和截面标志
PData<-pdata.frame(Data,index=c("PROVINCE","YEAR")) #指定截面单位和截面标志
summary(PData)
```

	YEAR	GDP	CZHL	PROVINCE
BEIJING-2000	2000	22460	77.54	BEIJING
BEIJING-2001	2001	25523	78.10	BEIJING
BEIJING-2002	2002	28449	79.50	BEIJING
BEIJING-2003	2003	32061	79.10	BEIJING
BEIJING-2004	2004	41099	78.60	BEIJING
BEIJING-2005	2005	45444	83.62	BEIJING
BEIJING-2006	2006	50467	84.33	BEIJING
BEIJING-2007	2007	58204	84.50	BEIJING
BEIJING-2008	2008	63029	84.90	BEIJING
BEIJING-2009	2009	68788	85.00	BEIJING
HEBEI-2000	2000	7663	26.08	HEBEI
HEBEI-2001	2001	8362	30.70	HEBEI

```
> summary(PData_pool<-plm(CZHL~GDP,data=PData,model="pooling"))
Pooling Model

Call:
plm(formula = CZHL ~ GDP, data = PData, model = "pooling")

Balanced Panel: n = 6, T = 10, N = 60

Residuals:
    Min.     1st Qu.     Median     3rd Qu.     Max.
-17.28766  -8.99435  -0.45542   7.49416  22.90659

Coefficients:
              Estimate Std. Error t-value Pr(>|t|)
(Intercept)  3.7533e+01 2.8370e+00 13.2302 < 2.2e-16 ***
GDP          7.6135e-04 9.2010e-05  8.2747 2.125e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares:    15101
Residual Sum of Squares: 6925.2
R-Squared:              0.5414
Adj. R-Squared: 0.53349
F-statistic: 68.4711 on 1 and 58 DF, p-value: 2.1248e-11
```

■ Stata的面板分析示例：城镇化率的混合OLS估计

```
encode PROVINCE, generate(PROVINCE_1) //转化为数字型  
xtset PROVINCE_1 YEAR //指定面板中的截面单位和截面
```

```
. xtset PROVINCE_1 YEAR  
    panel variable:  PROVINCE_1 (strongly balanced)  
    time variable:  YEAR, 2000 to 2009  
            delta:  1 unit
```

```
. xtline GDP
```

```
. reg CZHL GDP
```

Source	SS	df	MS	Number of obs	=	60
Model	8175.42938	1	8175.42938	F(1, 58)	=	68.47
Residual	6925.17851	58	119.399629	Prob > F	=	0.0000
Total	15100.6079	59	255.942507	R-squared	=	0.5414
				Adj R-squared	=	0.5335
				Root MSE	=	10.927

CZHL	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
GDP	.0007614	.000092	8.27	0.000	.0005772 .0009455
_cons	37.5334	2.836952	13.23	0.000	31.85462 43.21218



■ Stata的面板分析示例：城镇化率的混合OLS估计

```
. reg CZHL GDP
```

Source	SS	df	MS	Number of obs	=	60
Model	8175.42938	1	8175.42938	F(1, 58)	=	68.47
Residual	6925.17851	58	119.399629	Prob > F	=	0.0000
				R-squared	=	0.5414
				Adj R-squared	=	0.5335
Total	15100.6079	59	255.942507	Root MSE	=	10.927

CZHL	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
GDP	.0007614	.000092	8.27	0.000	.0005772	.0009455
_cons	37.5334	2.836952	13.23	0.000	31.85462	43.21218

```
. reg CZHL GDP, vce(cluster PROVINCE_1) //混合估计采用聚类稳健标准误
```

Linear regression		Number of obs	=	60
		F(1, 5)	=	26.49
		Prob > F	=	0.0036
		R-squared	=	0.5414
		Root MSE	=	10.927

(Std. Err. adjusted for 6 clusters in PROVINCE_1)

CZHL	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
GDP	.0007614	.0001479	5.15	0.004	.0003811	.0011416
_cons	37.5334	6.61947	5.67	0.002	20.51751	54.54929

- 普通标准误是“误差项独立同分布+同方差”假设下的，面板数据中通常不满足：
 - 同一截面单位不同时间的误差项间可能存在自相关性
 - 不同截面单位的误差项的方差可能不等(异方差)

$$y_{it} = \alpha + \mathbf{X}_{it}'\boldsymbol{\beta} + v_{it}, i = 1, \dots, N; t = 1, \dots, T$$

- 处理策略：计算聚类(cluster)稳健标准误
 - 对每个组内(截面单位)进行回归分析，计算残差平方和(自由度 $T - K - 1$)
 - 所有组(截面单位)的残差平方和之和除以自由度 $N(T - K - 1)$ ，开方得到聚类稳健标准误

混合OLS估计存在的问题

- 混合OLS估计未对数据中可能存在的异质性加以控制 (默认不存在异质性)
 - 例：基于若干月份各地区居民的腊肉购买数据，分析腊肉价格对其购买需求量的影响
 - y : 需求量; x : 需求量滞后一期、居民收入和价格 (均随时间和地区变化)
 - 异质性表现，如：
 - 居民饮食偏好的地区差异 (随地区变化但一般不随月份变化)
 - 媒体宣传效应的差异 (随月份变化，但在各地区不变)
 - 当这些异质性没有体现在模型中，且与需求量和自变量相关时，将导致自变量遗漏问题

混合OLS估计存在的问题

■ 调整模型

- 第一，很多可观测的随截面单位变化而不随时间变化的异质性因素(地区人口结构，产业结构等，记为 $\mathbf{Z}$)会影响被解释变量且与自变量相关，未能进入模型：变量遗漏
 - 变量遗漏导致零条件均值假定不满足，混合OLS估计不一致，重设模型：

$$y_{it} = \alpha + \mathbf{X}_{it}'\boldsymbol{\beta} + \mathbf{Z}_i'\boldsymbol{\gamma} + v_{it}$$

$\mathbf{Z}$ 为随截面单位变化但不随时间变化(短面板)的可观测变量

- 为简便，也可统一记为 $\mathbf{x}_{it}$ ，并可拓展至长面板

$$y_{it} = \alpha + \mathbf{x}_{it}'\boldsymbol{\beta} + v_{it}, i = 1, \dots, N; t = 1, \dots, T$$

where $\mathbf{x}_{it}$ is $1 \times K$ and can contain observable variables that change across t but not i , variables that change across i but not t , and variables that change across i and t .

- 第二，很多不可观测的随截面单位变化而不随时间变化的异质性因素（政策扶持等）存在于 v_{it} 中：变量遗漏

- 重设模型：

$$y_{it} = \alpha + \mathbf{X}_{it}'\boldsymbol{\beta} + \mathbf{Z}_i'\boldsymbol{\gamma} + v_{it}, i = 1, \dots, N; t = 1, \dots, T$$

$$y_{it} = \alpha + \mathbf{X}_{it}'\boldsymbol{\beta} + \mathbf{Z}_i'\boldsymbol{\gamma} + (c_i + u_{it}) \quad v_{it} = c_i + u_{it} \quad \text{称为不可观测效应模型或个体效应模型}$$

- c_i 为影响 y 且不可观测的效应（异质性），不随时间变动（系数约束为1源于不可观测无法估计系数）
- u_{it} 为影响 y 且随时间和截面单位变化的因素，称为特异误差（idiosyncratic error）：

- 通常与 c_i 不相关： $E(u_{it} | \mathbf{X}_{it}', \mathbf{Z}_i', c_i) = 0$
- 一般认为不存在序列相关

- 说明：可能还存在仅随时间变化的不可观测的异质性因素 d_t

- 单向效应和双向效应
- 短面板可忽略

$$y_{it} = \alpha + \mathbf{X}_{it}'\boldsymbol{\beta} + \mathbf{Z}_i'\boldsymbol{\gamma} + (c_i + d_t + u_{it})$$

个体效应模型

- 模型形式: $y_{it} = \alpha + \mathbf{X}_{it}'\boldsymbol{\beta} + \mathbf{Z}_i'\boldsymbol{\gamma} + (c_i + u_{it})$ $y_{it} = \alpha + \mathbf{x}_{it}'\boldsymbol{\beta} + (c_i + u_{it})$ $v_{it} = c_i + u_{it}$

where $\mathbf{x}_{it}$ is $1 \times K$ and can contain observable variables that change across t but not i , variables that change across i but not t , and variables that change across i and t .

- 采用OLS得到一致性估计的条件: 需满足零条件均值假定: $E(v_{it} | \mathbf{x}) = 0$

- 需关注不可观测的效应 (异质性):

- 若: $\text{Cov}(\mathbf{x}_{it}, c_i) = \mathbf{0}, t = 1, 2, \dots, T$ 满足: $E(v_{it} | \mathbf{x}) = 0$ 称为随机效应模型 (Random Effects Model), 这里为个体随机效应模型

- 混合OLS估计具有一致性, 但这是个很强的假定

- 若: $\text{Cov}(\mathbf{x}_{it}, c_i) \neq \mathbf{0}, t = 1, 2, \dots, T$ 不满足: $E(v_{it} | \mathbf{x}) = 0$

- 较为常见: 政策扶持等往往与经济发展(GDP)等解释变量有关

- 称为固定效应模型 (Fix Effects Model), 这里为个体固定效应模型

- 混合OLS估计不具有有一致性, 需解决不可观测效应的遗漏问题

- 面板数据提供了一种好的解决思路

个体固定效应模型的参数估计

$$y_{it} = \alpha + \mathbf{x}_{it}'\boldsymbol{\beta} + v_{it}, i = 1, \dots, N; t = 1, \dots, T$$

$$v_{it} = c_i + u_{it}$$

- 不可观测的效应与 $\mathbf{x}$ 相关时的估计问题：
 - 允许 $E(c_i|\mathbf{x}_i)$ 是 $\mathbf{x}_i$ 的任何函数(事实上变量 c 遗漏将导致变量 $\mathbf{x}$ 内生性)
 - 设法消除 c ，估计方法：
 - 一阶差分方程(first-differenced equation, FD)估计法
 - 固定效应变换(fixed effects transformation, FE)估计法, 也称组内变换估计(Within Estimator)

个体固定效应模型的参数估计： 一阶差分估计法

$$y_{it} = \alpha + \mathbf{x}_{it}'\boldsymbol{\beta} + v_{it}, i = 1, \dots, N; t = 1, \dots, T \quad v_{it} = c_i + u_{it}$$

- 因样本具有**配对**特征，可对每个截面单位依时间做差
 - 如滞后1期的1阶差分：

$$\Delta y_{it} = y_{it} - y_{i,t-1} \quad \Delta \mathbf{x}_{it} = \mathbf{x}_{it} - \mathbf{x}_{i,t-1} \quad \Delta u_{it} = u_{it} - u_{i,t-1}$$

- 对差分数据采用OLS估计，得到 $\boldsymbol{\beta}$ 的**一阶差分估计**

$$\Delta y_{it} = \Delta \mathbf{x}_{it}'\boldsymbol{\beta} + \Delta u_{it}, \quad t = 2, 3, \dots, T$$

- 差分后对每个截面单位都丢失了第1期数据， $t=2$ 开始
- 需假定 Δu_{it} 与 Δx_i 无关
- 效应 c_i 被差分掉，差分方程中的 $\boldsymbol{\beta}$ 估计具有一致性
- Δu_{it} 通常不存在序列相关性(即使 u_{it} 是个随机游走，序列相关， Δu_{it} 无序列相关)

■ R和Stata的一阶差分估计示例

```
library("plm")
Data<-read.table(file="面板数据示例.txt",header=TRUE,sep=" ")
#PData<-plm.data(Data,index=c("PROVINCE","YEAR")) #指定截面单位和截面标志
PData<-pdata.frame(Data,index=c("PROVINCE","YEAR")) #指定截面单位和截面标志
summary(PData)
```

```
> summary(PData_fd<-plm(CZHL~GDP,data=PData,model="fd")) #一阶差分估计
Oneway (individual) effect First-Difference Model
```

Call:

```
plm(formula = CZHL ~ GDP, data = PData, model = "fd")
```

Balanced Panel: n=6, T=10, N=60

Residuals :

Min.	1st Qu.	Median	3rd Qu.	Max.
-11.500	-0.836	-0.309	0.631	4.900

Coefficients :

	Estimate	Std. Error	t-value	Pr(> t)
(intercept)	5.6849e-01	6.4069e-01	0.8873	0.3790
GDP	8.7061e-05	1.6051e-04	0.5424	0.5899

Total Sum of Squares: 316.35

Residual Sum of Squares: 314.57

R-Squared : 0.0056259

Adj. R-Squared : 0.0054175

F-statistic: 0.294202 on 1 and 52 DF, p-value: 0.58986

```
encode PROVINCE, generate(PROVINCE_1) //转化为数字型
xtset PROVINCE_1 YEAR //指定面板中的截面单位和截面
```

```
. xtset PROVINCE_1 YEAR
      panel variable:  PROVINCE_1 (strongly balanced)
      time variable:  YEAR, 2000 to 2009
              delta:  1 unit
```

```
gen diffCZHL = D.CZHL //计算差分序列
gen diffGDP = D.GDP
```

```
. reg diffCZHL diffGDP //一阶差分估计
```

Source	SS	df	MS	Number of obs	=	54
Model	1.77973262	1	1.77973262	F(1, 52)	=	0.29
Residual	314.5662	52	6.04935	Prob > F	=	0.5899
				R-squared	=	0.0056
				Adj R-squared	=	-0.0135
Total	316.345933	53	5.96879118	Root MSE	=	2.4595

diffCZHL	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
diffGDP	.0000871	.0001605	0.54	0.590	-.000235	.0004091
_cons	.5684941	.6406866	0.89	0.379	-.7171376	1.854126

个体固定效应模型的参数估计： 一阶差分估计法

- 一阶差分方程法的优势

$$y_{it} = \alpha + \mathbf{X}_{it}'\boldsymbol{\beta} + \mathbf{Z}_i'\boldsymbol{\gamma} + (c_i + u_{it})$$

- 使假定 Δu_{it} 与 Δx_{it} 无关更容易满足

$$\Delta y_{it} = \Delta \mathbf{x}_{it}'\boldsymbol{\beta} + \Delta u_{it}, \quad t = 2, 3, \dots, T$$

- x_{it} 与 c_i 相关无妨, c_i 会被差分掉, 解决了不可观测的变量遗漏导致的估计问题

- 一阶差分方程法的劣势

- 差分可能大大减少变量 $\mathbf{X}$ 的变差

- $\mathbf{X}_{it}$ 可能有明显差异, 但 $\Delta \mathbf{x}_{it}$ 可能变化很小, 导致一阶差分估计量的方差较大

- 时间上恒定的变量 $\mathbf{Z}$ 均被差分掉, 无法估计它们的效应

- 不适用于非平衡面板数据

个体固定效应模型的参数估计： 固定效应变换估计法

- 固定效应变换(fixed effects transformation)：也称组内变换(within transformation)，解决不可观测的变量遗漏问题

- 第一步：对每个截面单位 i 计算在时间上的平均，得到关于截面单位的截面方程

$$\bar{y}_i = \bar{\mathbf{x}}_i \boldsymbol{\beta} + c_i + \bar{u}_i$$

$$\bar{y}_i = T^{-1} \sum_{t=1}^T y_{it}, \quad \bar{\mathbf{x}}_i = T^{-1} \sum_{t=1}^T \mathbf{x}_{it}, \quad \bar{u}_i = T^{-1} \sum_{t=1}^T u_{it}$$

- 有理由认为不可观测效应 c_i 也做了基于时间的平均
- 截面方程的OLS估计称为组间估计量(Between estimator)
 - 通常不采纳组间估计，因为 $\text{Cov}(c_i, \bar{\mathbf{x}}_i) \neq 0$ 导致组间估计是不一致的

■ 固定效应变换 (fixed effects transformation, FE)

- 第一步：对每个截面单位*i*计算在时间上的平均得到每个截面单位的截面方程

$$\bar{y}_i = \bar{\mathbf{x}}_i \boldsymbol{\beta} + c_i + \bar{u}_i \quad \bar{y}_i = T^{-1} \sum_{t=1}^T y_{it}, \quad \bar{\mathbf{x}}_i = T^{-1} \sum_{t=1}^T \mathbf{x}_{it}, \quad \bar{u}_i = T^{-1} \sum_{t=1}^T u_{it}$$

- 第二步：做各截面单位方程对截面方程的差，得到除时间均值后的方程：

$$y_{it} - \bar{y}_i = (\mathbf{x}_{it} - \bar{\mathbf{x}}_i) \boldsymbol{\beta} + u_{it} - \bar{u}_i \rightarrow \ddot{y}_{it} = \ddot{\mathbf{x}}_{it} \boldsymbol{\beta} + \ddot{u}_{it}, \quad t = 1, 2, \dots, T$$

$$\ddot{y}_{it} \equiv y_{it} - \bar{y}_i, \quad \ddot{\mathbf{x}}_{it} \equiv \mathbf{x}_{it} - \bar{\mathbf{x}}_i, \quad \ddot{u}_{it} \equiv u_{it} - \bar{u}_i$$

- 方程中不可观测的效应 c_i 消失了；非时变的变量 $\mathbf{Z}$ 去除了；模型无常数项
- 对除时间均值数据采用OLS估计，得到的估计称为固定效应变换(组内)估计量，为一致性估计(默认特异性误差项 $\ddot{u}_{it}$ 无序列相关)

■ 固定效应估计的优势和劣势

- 通过固定效应变换消除不可观测的异质性，保证固定效应估计的一致性
- 凡在时间上恒定的变量 $\mathbf{Z}$ 都随固定效应变换而消失，无法估计它们的影响效应

■ 固定效应变换估计的实现

```
> summary(PData_within<-plm(CZHL~GDP,data=PData,model="within",effect="individual"))
Oneway (individual) effect within Model
```

```
Call:
plm(formula = CZHL ~ GDP, data = PData, effect = "individual",
     model = "within")
```

Balanced Panel: n = 6, T = 10, N = 60

```
Residuals:
    Min. 1st Qu.  Median 3rd Qu.    Max.
-9.4365 -1.0195  0.8116  1.5557  4.6653
```

```
Coefficients:
            Estimate Std. Error t-value Pr(>|t|)
GDP  2.3676e-04  3.0455e-05   7.7741 2.571e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Total Sum of Squares:    780.98
Residual Sum of Squares: 364.89
R-Squared:                0.53278
Adj. R-Squared: 0.47988
F-statistic: 60.4363 on 1 and 53 DF, p-value: 2.5715e-10
```

```
. xtreg CZHL GDP,fe
```

```
Fixed-effects (within) regression           Number of obs   =          60
Group variable: PROVINCE_1                  Number of groups =           6
```

```
R-sq:                                         Obs per group:
      within = 0.5328                         min =          10
      between = 0.8430                       avg =         10.0
      overall = 0.5414                       max =          10
```

```
corr(u_i, Xb) = 0.6097                      F(1,53)         =        60.44
                                           Prob > F        =        0.0000
```

	CZHL	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
	GDP	.0002368	.0000305	7.77	0.000	.0001757	.0002978
	_cons	51.56697	.8823148	58.45	0.000	49.79727	53.33667
	sigma_u	14.451081					
	sigma_e	2.623886					
	rho	.96808444	(fraction of variance due to u_i)				

```
F test that all u_i=0: F(5, 53) = 190.57                      Prob > F = 0.0000
```

• 关于 R^2

- 整体 R^2 : $\text{corr}(y_{it}, \mathbf{x}_{it}\hat{\boldsymbol{\beta}})^2$
- 组内 R^2 : $\text{corr}(\ddot{y}_{it}, \ddot{\mathbf{x}}_{it}\hat{\boldsymbol{\beta}})^2$
- 组间 R^2 : $\text{corr}(\bar{y}_i, \bar{\mathbf{x}}_i\hat{\boldsymbol{\beta}})^2$
- 模型应无常数项，其含义后面讲

$$y_{it} = \alpha + \mathbf{X}_{it}'\boldsymbol{\beta} + v_{it}, i = 1, \dots, N; t = 1, \dots, T$$

$$\ddot{y}_{it} = \ddot{\mathbf{x}}_{it}\boldsymbol{\beta} + \ddot{u}_{it},$$

$$\bar{y}_i = \bar{\mathbf{x}}_i\boldsymbol{\beta} + c_i + \bar{u}_i$$

■ 固定效应变换估计的实现: 采用聚类稳健标准误

```
. xtreg CZHL GDP,fe
```

```
Fixed-effects (within) regression
Group variable: PROVINCE_1
```

```
R-sq:
  within = 0.5328
  between = 0.8430
  overall = 0.5414
```

```
corr(u_i, Xb) = 0.6097
```

CZHL	Coef.	Std. Err.	t
GDP	.0002368	.0000305	7.77
_cons	51.56697	.8823148	58.45
sigma_u	14.451081		
sigma_e	2.623886		
rho	.96808444	(fraction of variance due to u_i)	

```
F test that all u_i=0: F(5, 53) = 190.57
```

```
. xtreg CZHL GDP,fe r //固定效应变换估计, 组内估计,r:表示计算聚类稳健标准误
```

```
Fixed-effects (within) regression
Group variable: PROVINCE_1
```

```
R-sq:
  within = 0.5328
  between = 0.8430
  overall = 0.5414
```

```
corr(u_i, Xb) = 0.6097
```

```
(Std. Err. adjusted for 6 clusters in PROVINCE_1)
```

CZHL	Coef.	Robust Std. Err.	t
GDP	.0002368	.0000538	4.40
_cons	51.56697	1.437968	35.86
sigma_u	14.451081		
sigma_e	2.623886		
rho	.96808444	(fraction of variance due to u_i)	

```
Number of obs = 60
Number of groups = 6
```

```
Obs per group:
  min = 10
  avg = 10.0
  max = 10
```

```
F(1,5) = 19.40
Prob > F = 0.0070
```

```
. xtreg CZHL GDP,fe vce(cluster PROVINCE_1) //固定效应变换估计, 组内估计,计算聚类稳健标准误
```

```
Fixed-effects (within) regression
Group variable: PROVINCE_1
```

```
R-sq:
  within = 0.5328
  between = 0.8430
  overall = 0.5414
```

```
corr(u_i, Xb) = 0.6097
```

```
(Std. Err. adjusted for 6 clusters in PROVINCE_1)
```

CZHL	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]
GDP	.0002368	.0000538	4.40	0.007	.0000986 .0003749
_cons	51.56697	1.437968	35.86	0.000	47.87056 55.26338
sigma_u	14.451081				
sigma_e	2.623886				
rho	.96808444	(fraction of variance due to u_i)			

- 其他问题：传统的个体固定效应估计认为，可将 c_i 视为第 i 个截面单位对 y 的效应，是个待估计参数

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + c_i + u_{it}, \quad t = 1, \dots, T$$

- 再看模型：引入截面单位的虚拟自变量

$$y_{it} = \beta_1 x_{it} + \gamma_1 + \gamma_2 W_2 + \dots + \gamma_N W_N + \varepsilon_{it}, \quad t = 1, 2, \dots, T$$

$$W_i = \begin{cases} 1, & \text{如果属于第} i \text{个个体, } i = 2, \dots, N. \\ 0, & \text{其他} \end{cases}$$

- 模型一般形式：个体变截距模型；引入交乘项拓展为个体变系数模型

$$y_{it} = \gamma_i + \boldsymbol{\beta}\mathbf{x}_{it} + u_{it}, \quad i = 1, 2, \dots, N, t = 1, 2, \dots, T$$

- γ_i 随截面单位变化

- 其他问题：传统的固定效应估计认为，可将 c_i 视为第 i 个截面单位对 y 的效应，是个待估计参数

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + c_i + u_{it}, \Rightarrow y_{it} = \gamma_i + \boldsymbol{\beta}\mathbf{x}_{it} + u_{it}, i = 1, 2, \dots, N, t = 1, 2, \dots, T$$

- 估计方法：引入截面单位的虚拟自变量，采用混合估计

```
> summary(PData_within<-plm(CZHL~GDP+PROVINCE,data=PData,model="pooling",effect="individual"))
Pooling Model
```

Call:

```
plm(formula = CZHL ~ GDP + PROVINCE, data = PData, effect = "individual",
     model = "pooling")
```

Balanced Panel: n = 6, T = 10, N = 60

Residuals:

Min.	1st Qu.	Median	3rd Qu.	Max.
-9.4365	-1.0195	0.8116	1.5557	4.6653

Coefficients:

	Estimate	Std. Error	t-value	Pr(> t)
(Intercept)	7.1208e+01	1.5645e+00	45.5138	< 2.2e-16 ***
GDP	2.3676e-04	3.0455e-05	7.7741	2.571e-10 ***
PROVINCEHEBEI	-3.8622e+01	1.4677e+00		
PROVINCEHEILONGJIANG	-2.2401e+01	1.4703e+00		
PROVINCEJIANGSU	-2.8172e+01	1.3060e+00		
PROVINCETIANJIN	-5.3472e+00	1.1966e+00		
PROVINCEZHEJIANG	-2.3302e+01	1.2736e+00		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0

Total Sum of Squares: 15101

Residual Sum of Squares: 364.89

R-Squared: 0.97584

Adj. R-Squared: 0.9731

F-statistic: 356.722 on 6 and 53 DF, p-value: < 2.22e-16

- 截面单位虚拟自变量的混合OLS估计等于固定效应估计
- 截距为北京的截面单位效应(为参照类别)

$$\hat{c}_i = \bar{y}_i - \bar{\mathbf{x}}_i \hat{\boldsymbol{\beta}}_{FE}$$

```
> GDPmeanP<-tapply(PData$GDP, INDEX=PData$PROVINCE, FUN=mean)
> CZHLmeanP<-tapply(PData$CZHL, INDEX=PData$PROVINCE, FUN=mean)
> CZHLmeanP- (2.3676e-04)*GDPmeanP
      BEIJING      HEBEI HEILONGJIANG      JIANGSU      TIANJIN      ZHEJIANG
71.20753    32.58524    48.80708    43.03554    65.86031    47.90569
> mean(CZHLmeanP- (2.3676e-04)*GDPmeanP)
[1] 51.5669
```

$$E(\hat{c}_i) = E(\bar{y}_i - \bar{\mathbf{x}}_i \hat{\boldsymbol{\beta}}_{FE})$$

- 即为前面Stata的常数项

- 其他问题：传统的个体固定效应估计认为，可将 c_i 视为第 i 个截面单位对 y 的效应，是个待估计参数

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + c_i + u_{it}, \Rightarrow y_{it} = \gamma_i + \boldsymbol{\beta}\mathbf{x}_{it} + u_{it}, i = 1, 2, \dots, N, t = 1, 2, \dots, T$$

- 估计方法：引入截面单位的虚拟自变量, 采用混合估计

```
. tab PROVINCE,gen(PROVINCE)
```

生成省份虚拟自变量

PROVINCE	Freq.	Percent	Cum.
BEIJING	10	16.67	16.67
HEBEI	10	16.67	33.33
HEILONGJIANG	10	16.67	50.00
JIANGSU	10	16.67	66.67
TIANJIN	10	16.67	83.33
ZHEJIANG	10	16.67	100.00
Total	60	100.00	

```
reg CZHL GDP PROVINCE2 - PROVINCE6
```

Source	SS	df	MS	Number of obs	=	60
Model	14735.7147	6	2455.95244	F(6, 53)	=	356.72
Residual	364.893218	53	6.8847777	Prob > F	=	0.0000
Total	15100.6079	59	255.942507	R-squared	=	0.9758
				Adj R-squared	=	0.9731
				Root MSE	=	2.6239

CZHL	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
GDP	.0002368	.0000305	7.77	0.000	.0001757	.0002978
PROVINCE2	-38.62237	1.46771	-26.31	0.000	-41.56623	-35.67852
PROVINCE3	-22.40054	1.470251	-15.24	0.000	-25.34949	-19.45159
PROVINCE4	-28.17204	1.306001	-21.57	0.000	-30.79155	-25.55254
PROVINCE5	-5.347248	1.196607	-4.47	0.000	-7.747338	-2.947157
PROVINCE6	-23.30189	1.273567	-18.30	0.000	-25.85634	-20.74744
_cons	71.20765	1.564528	45.51	0.000	68.06961	74.3457

- 其他问题：在估计个体固定效应模型时考虑时间异质性，即双向固定效应
 - 方法：引入时间虚拟自变量,采用固定效应变换估计

$$y_{it} = \alpha + \mathbf{X}_{it}'\boldsymbol{\beta} + \mathbf{Z}_i'\boldsymbol{\gamma} + (c_i + d_t + u_{it})$$

```
> summary(PData_within<-plm(CZHL~GDP+YEAR,data=PData,model="within",effect="individual"))
Oneway (individual) effect Within Model

Call:
plm(formula = CZHL ~ GDP + YEAR, data = PData, effect = "individual",
     model = "within")

Balanced Panel: n = 6, T = 10, N = 60

Residuals:
      Min.      1st Qu.      Median      3rd Qu.      Max.
-9.346847 -0.644369 -0.088124  0.759598  5.065425

Coefficients:
              Estimate Std. Error t-value Pr(>|t|)
GDP          1.1157e-04  7.6276e-05  1.4627 0.150651
YEAR2001     1.4067e+00  1.3996e+00  1.0050 0.320377
YEAR2002     3.9118e+00  1.4166e+00  2.7613 0.008365 **
YEAR2003     2.6683e+00  1.4671e+00  1.8187 0.075762 .
YEAR2004     1.5275e+00  1.5780e+00  0.9680 0.338321
YEAR2005     4.8876e+00  1.7322e+00  2.8216 0.007145 **
YEAR2006     5.2559e+00  1.9181e+00  2.7402 0.008838 **
YEAR2007     5.5518e+00  2.1832e+00  2.5430 0.014583 *
YEAR2008     5.9650e+00  2.5020e+00  2.3841 0.021501 *
YEAR2009     4.3656e+00  2.7212e+00  1.6043 0.115803
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares:      780.98
Residual Sum of Squares: 256.83
R-Squared:                0.67115
Adj. R-Squared: 0.55904
F-statistic: 8.97978 on 10 and 44 DF, p-value: 7.8284e-08
```

- 其他问题：在估计个体固定效应模型时考虑时间异质性，即双向固定效应
 - 方法：引入时间虚拟自变量,采用固定效应变换估计

$$y_{it} = \alpha + \mathbf{X}_{it}'\boldsymbol{\beta} + \mathbf{Z}_i'\boldsymbol{\gamma} + (c_i + d_t + u_{it})$$

. tab YEAR,gen(YEAR)

YEAR	Freq.	Percent	Cum.
2000	6	10.00	10.00
2001	6	10.00	20.00
2002	6	10.00	30.00
2003	6	10.00	40.00
2004	6	10.00	50.00
2005	6	10.00	60.00
2006	6	10.00	70.00
2007	6	10.00	80.00
2008	6	10.00	90.00
2009	6	10.00	100.00
Total	60	100.00	

转成字符型后才可生成时间虚拟自变量

同等效果：

```
destring YEAR,replace
xtreg CZHL GDP i.YEAR,fe
```

- 常数项为2000年的固定效应估计

```
. xtreg CZHL GDP YEAR2 - YEAR10,fe
```

Fixed-effects (within) regression
Group variable: PROVINCE_1

Number of obs = 60
Number of groups = 6

R-sq:

within = 0.6711
between = 0.8430
overall = 0.2540

Obs per group:

min = 10
avg = 10.0
max = 10

corr(u_i, Xb) = 0.3348

F(10,44) = 8.98
Prob > F = 0.0000

	CZHL	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
GDP		.0001116	.0000763	1.46	0.151	-.0000422 .0002653
YEAR2		1.406659	1.399617	1.01	0.320	-1.414084 4.227401
YEAR3		3.911752	1.416612	2.76	0.008	1.056759 6.766745
YEAR4		2.66828	1.467108	1.82		
YEAR5		1.52752	1.577968	0.97		
YEAR6		4.887629	1.732234	2.82		
YEAR7		5.255904	1.918077	2.74		
YEAR8		5.551774	2.183168	2.54		
YEAR9		5.965045	2.502046	2.38		
YEAR10		4.36565	2.72122	1.60		
_cons		51.36184	1.434291	35.81		
sigma_u		15.74729				
sigma_e		2.4159979				
rho		.97700268	(fraction of variance)			

F test that all u_i=0: F(5, 44) = 122.43

```
. test YEAR2 YEAR3 YEAR4 YEAR5 YEAR6 YEAR7 YEAR8 YEAR9 YEAR10
```

(1) YEAR2 = 0
(2) YEAR3 = 0
(3) YEAR4 = 0
(4) YEAR5 = 0
(5) YEAR6 = 0
(6) YEAR7 = 0
(7) YEAR8 = 0
(8) YEAR9 = 0
(9) YEAR10 = 0

F(9, 44) = 2.06
Prob > F = 0.0550

时间的联合检验在0.05显著性水平下不显著

时间固定效应模型的参数估计： 固定效应变换估计法

- 视为长面板的情况：时间固定效应模型

$$y_{it} = \alpha + \mathbf{X}_{it}'\boldsymbol{\beta} + (c_j) + d_t + u_{it}$$

- 对每个时间t计算在截面单位上的平均得到关于截面(时间)的
截面方程
- 做差消除不可观测的效应 d_t

```
> summary(PData_within<-plm(CZHL~GDP,data=PData,model="within",effect="time"))
Oneway (time) effect Within Model

Call:
plm(formula = CZHL ~ GDP, data = PData, effect = "time",
     model = "within")

Balanced Panel: n = 6, T = 10, N = 60

Residuals:
    Min.   1st Qu.   Median   3rd Qu.    Max.
-19.7183  -5.7010  -2.8948   6.4721  16.1800

Coefficients:
            Estimate Std. Error t-value Pr(>|t|)
GDP 0.00118329  0.00010086  11.733 7.713e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares:    14589
Residual Sum of Squares: 3829.9
R-Squared:              0.73748
Adj. R-Squared:         0.68391
F-statistic: 137.653 on 1 and 49 DF, p-value: 7.7128e-16
```

- 传统的固定效应估计认为：可将 d_t 视为时间 t 对 y 的效应，是个待估计参数
 - 引入时间的虚拟自变量，采用pooling估计

```
> summary(PData_within<-plm(CZHL~GDP+YEAR,data=PData,model="pooling",effect="time"))
Pooling Model
```

Call:

```
plm(formula = CZHL ~ GDP + YEAR, data = PData, effect = "time",
     model = "pooling")
```

Balanced Panel: n = 6, T = 10, N = 60

Residuals:

Min.	1st Qu.	Median	3rd Qu.	Max.
-19.7183	-5.7010	-2.8948	6.4721	16.1800

Coefficients:

	Estimate	Std. Error	t-value	Pr(> t)
(Intercept)	3.6731e+01	3.8630e+00	9.5084	1.044e-12 ***
GDP	1.1833e-03	1.0086e-04	11.7326	7.713e-16 ***
YEAR2001	-2.1039e-01	5.1065e+00	-0.0412	0.9673038
YEAR2002	4.3848e-01	5.1147e+00	0.0857	0.9320309
YEAR2003	-3.7201e+00	5.1396e+00	-0.7238	0.4726227
YEAR2004	-8.8385e+00	5.1967e+00	-1.7008	0.0953175 .
YEAR2005	-9.5438e+00	5.2819e+00	-1.8069	0.0769191 .
YEAR2006	-1.3243e+01	5.3930e+00	-2.4555	0.0176624 *
YEAR2007	-1.8045e+01	5.5664e+00	-3.2418	0.0021388 **
YEAR2008	-2.3220e+01	5.7963e+00	-4.0060	0.0002094 ***
YEAR2009	-2.8464e+01	5.9664e+00	-4.7707	1.690e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares: 15101

Residual Sum of Squares: 3829.9

R-Squared: 0.74638

Adj. R-Squared: 0.69462

F-statistic: 14.4199 on 10 and 49 DF, p-value: 1.8267e-11

```
> GDPmeanP<-tapply(PData$GDP, INDEX=PData$YEAR, FUN=mean)
```

```
> CZHLmeanP<-tapply(PData$CZHL, INDEX=PData$YEAR, FUN=mean)
```

```
> CZHLmeanP- (1.1833e-03)*GDPmeanP
```

2000	2001	2002	2003	2004	2005	2006	2007	2008	2009
36.730588	36.520186	37.169044	33.010468	27.891983	27.186665	23.487905	18.685022	13.510296	8.266484

- 时点变截距模型；引入交乘项拓展为时点变系数模型

$$y_{it} = \delta_t + \mathbf{X}'_{it}\boldsymbol{\beta} + u_{it}, \delta_t \text{随截面变化}$$

- 时间虚拟自变量的混合OLS估计等于固定效应估计
- 截距为2000年的效应(为参照类别)

$$\hat{d}_t = \bar{y}_t - \bar{\mathbf{x}}_t \hat{\boldsymbol{\beta}}_{FE}$$

个体随机效应模型的参数估计

- 个体随机效应模型:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + v_{it} \quad v_{it} = c_i + u_{it}$$

$$E(v_{it} | \mathbf{x}_i) = 0, \quad t = 1, 2, \dots, T$$

ASSUMPTION RE.1:

(a) $E(u_{it} | \mathbf{x}_i, c_i) = 0, t = 1, \dots, T.$

(b) $E(c_i | \mathbf{x}_i) = E(c_i) = 0$

where $\mathbf{x}_i \equiv (\mathbf{x}_{i1}, \mathbf{x}_{i2}, \dots, \mathbf{x}_{iT})$.

- 可采用OLS估计, 但面板数据的特点决定了 v_{it} 序列可能相关而导致的问题

- 考虑 v_{it} 序列可能相关的问题 $y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + v_{it}$ $v_{it} = c_i + u_{it}$

$$E(u_{it}^2) = \sigma_u^2, \quad t = 1, 2, \dots, T \quad E(u_{it}u_{is}) = 0, \quad \text{all } t \neq s$$

$$E(v_{it}^2) = E(c_i^2) + 2E(c_i u_{it}) + E(u_{it}^2) = \sigma_c^2 + \sigma_u^2$$

$$\sigma_c^2 = E(c_i^2) \quad E(c_i u_{it}) = 0,$$

$$E(v_{it}v_{is}) = E[(c_i + u_{it})(c_i + u_{is})] = E(c_i^2) = \sigma_c^2$$

- 忽略序列相关将导致OLS估计量的方差估计偏低

$$\text{Var}(\hat{\beta}_1) = \text{SST}_x^{-2} \text{Var}\left(\sum_{t=1}^n x_t u_t\right) = \text{SST}_x^{-2} \left(\sum_{t=1}^n x_t^2 \text{Var}(u_t) + 2 \sum_{t=1}^{n-1} \sum_{j=1}^{n-t} x_t x_{t+j} E(u_t u_{t+j}) \right)$$

- 序列相关意味着存在模型设置不足，如对时间序列进行1阶自回归：

$$y_t = \beta_0 + \beta_1 y_{t-1} + u_t, \quad u_t = \rho u_{t-1} + e_t, \quad t = 1, 2, \dots, n$$

$$E(u_t | y_{t-1}) = 0.$$

u 是稳定的AR(1)

$$\begin{aligned} y_t &= \beta_0 + \beta_1 y_{t-1} + \rho(y_{t-1} - \beta_0 - \beta_1 y_{t-2}) + e_t \\ &= \beta_0(1 - \rho) + (\beta_1 + \rho)y_{t-1} - \rho\beta_1 y_{t-2} + e_t \\ &= \alpha_0 + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + e_t \end{aligned} \quad \text{AR}(2)$$

- 利用GLS解决序列相关问题

- 广义最小二乘法 (GLS)：误差项表示为稳定的AR(1)过程且 ρ 已知

$$y_t = \beta_0 + \beta_1 x_t + u_t, \text{ for all } t = 1, 2, \dots, n.$$

$$u_t = \rho u_{t-1} + e_t, t = 2, \dots, n. \quad \text{Var}(e_t | u_{t-1}) = \text{Var}(e_t) = \sigma_e^2. \quad e_t \text{是均值为0方差为}\sigma_e^2 \text{的IID序列}$$

- 一元回归模型为：

$$y_t = \beta_0 + \beta_1 x_t + u_t, \text{ for all } t = 1, 2, \dots, n.$$

$$y_t = \beta_0 + \beta_1 x_t + u_t. \quad - \rho \times \quad y_{t-1} = \beta_0 + \beta_1 x_{t-1} + u_{t-1}$$

$$y_t - \rho y_{t-1} = (1 - \rho)\beta_0 + \beta_1(x_t - \rho x_{t-1}) + e_t, t \geq 2,$$

$$e_t = u_t - \rho u_{t-1}.$$

$$\tilde{y}_t = (1 - \rho)\beta_0 + \beta_1 \tilde{x}_t + e_t, t \geq 2,$$

无序列相关

称为标差分数据 (quasi-differenced data)

- 对标差分数据进行OLS估计得到 β_1 的GLS估计
- 若 ρ 未知： y_t 对 x_t 回归后得到残差 $\hat{u}_t$ ，对残差进行如下回归得到 $\hat{\rho}$ 并得到标差分数据；对标差分数据进行OLS估计得到 β_1 的FGLS估计

$$\hat{u}_t \text{ on } \hat{u}_{t-1}, \text{ for all } t = 2, \dots, n,$$

个体随机效应模型的参数估计

■ 随机效应估计 (Random Effects Model, RE) 策略:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + v_{it} \quad v_{it} = c_i + u_{it}$$

$$\bar{y}_i = \bar{\mathbf{x}}_i\boldsymbol{\beta} + c_i + \bar{u}_i$$

■ 模型中 λ 的变化

$$y_{it} - \lambda \bar{y}_i = \beta_0(1 - \lambda) + \beta_1(x_{it1} - \lambda \bar{x}_{i1}) + \dots + \beta_k(x_{itk} - \lambda \bar{x}_{ik}) + (v_{it} - \lambda \bar{v}_i),$$

- λ 接近0, 随机效应估计接近混合OLS估计

- λ 接近1, 随机效应估计接近固定效应变换估计

- 固定效应估计是减去对时间的均值

- 随机效应估计是减去时间均值的一个比例, 使得:

- 随机效应估计中, 不随时间变化的解释变量可进入模型, 且可估计其影响效应

- λ 的估计: 为前面的 ρ , a 为不可观测的效应, λ 在R和Stata中记为 **theta**

$$\lambda = 1 - [\sigma_u^2 / (\sigma_u^2 + T\sigma_a^2)]^{1/2}, \quad \text{不可观测效应的方差大于} u \text{的方差且} T \text{较大时} \lambda \text{接近} 1$$

■ 案例的随机效应估计RE: 不可观测的效应为截面单位 c_i

```
> summary(PData_random<-plm(CZHL~GDP,data=PData,model="random",effect="individual"))
Oneway (individual) effect Random Effect Model
(Swamy-Arora's transformation)
```

```
Call:
plm(formula = CZHL ~ GDP, data = PData, effect = "individual",
     model = "random")
```

Balanced Panel: n = 6, T = 10, N = 60

Effects:

	var	std.dev	share
idiosyncratic	6.885	2.624	0.11
individual	55.503	7.450	0.89

theta: 0.8893

Residuals:

	Min.	1st Qu.	Median	3rd Qu.	Max.
	-10.32055	-0.76813	0.63569	1.52093	3.89085

Coefficients:

	Estimate	Std. Error	z-value	Pr(> z)
(Intercept)	5.1244e+01	3.5130e+00	14.5869	< 2.2e-16 ***
GDP	2.4884e-04	3.3611e-05	7.4035	1.327e-13 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares: 956.43

Residual Sum of Squares: 491.73

R-Squared: 0.48587

Adj. R-Squared: 0.477

Chisq: 54.8114 on 1 DF, p-value: 1.3267e-13

$$y_{it} = x_{it}\beta + v_{it} \quad v_{it} = c_i + u_{it}$$

$$v_{it} = c_i + u_{it}$$

$$E(v_{it}v_{is}) = E[(c_i + u_{it})(c_i + u_{is})] = E(c_i^2) = \sigma_c^2$$

$$E(v_{it}^2) = E(c_i^2) + 2E(c_i u_{it}) + E(u_{it}^2) = \sigma_c^2 + \sigma_u^2$$

$$1 - \text{Corr}(v_{it}, v_{is}) = \sigma_a^2 / (\sigma_a^2 + \sigma_u^2), t \neq s,$$

$$\text{Corr}(v_{it}, v_{is}) = \sigma_a^2 / (\sigma_a^2 + \sigma_u^2), t \neq s,$$

. xtreg CZHL GDP ,re theta //随机效应估计, 显示theta

Random-effects GLS regression	Number of obs	=	60
Group variable: PROVINCE_1	Number of groups	=	6
R-sq:	Obs per group:		
within = 0.5328	min =		10
between = 0.8430	avg =		10.0
overall = 0.5414	max =		10
corr(u_i, X)	= 0 (assumed)	Wald chi2(1)	= 54.81
theta	= .88930969	Prob > chi2	= 0.0000

CZHL	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
GDP	.0002488	.0000336	7.40	0.000	.000183	.0003147
_cons	51.24384	3.512995	14.59	0.000	44.35849	58.12918
sigma_u	7.4500357					
sigma_e	2.623886					
rho	.88964547	(fraction of variance due to u_i)				

固定效应估计FE还是随机效应估计RE?

- 普遍认为FE更令人信服，因为假定易满足
 - 但不随时间变化的变量无法估计其对 y 的效应，而RE可以估计
- 可通过统计检验(豪斯曼检验)确定采用FE还是RE
 - 原假设：不可观测的异质性 c_i 与 x_i 不相关 $E(c_i | \mathbf{x}_i) = E(c_i) = 0$

$$(\hat{\beta}_{FE} - \hat{\beta}_{RE})' [\text{Var}(\hat{\beta}_{FE}) - \text{Var}(\hat{\beta}_{RE})]^{-1} (\hat{\beta}_{FE} - \hat{\beta}_{RE}) \rightarrow \chi^2(K)$$

- 拒绝原假设时，RE不是一致性估计，应采用FE
- 无法推翻原假设时两者均可采用(固定效应估计也是一致性估计)，但一般认为随机效应估计更有效，应采用随机效应模型

```
> phptest(PData_within, PData_random) #固定效应变换法还是随机效应估计法
```

```
Hausman Test
```

```
data: CZHL ~ GDP
chisq = 0.72161, df = 1, p-value = 0.3956
alternative hypothesis: one model is inconsistent
```

采用RE

固定效应估计FE还是随机效应估计RE?

$$(\hat{\beta}_{FE} - \hat{\beta}_{RE})' [\text{Var}(\hat{\beta}_{FE}) - \text{Var}(\hat{\beta}_{RE})']^{-1} (\hat{\beta}_{FE} - \hat{\beta}_{RE}) \rightarrow \chi^2(K)$$

```
xtreg CZHL GDP i.YEAR,fe
est store FE
xtreg CZHL GDP i.YEAR,re
est store RE
hausman FE RE,sigmamore
```

—— Coefficients ——				
	(b) FE	(B) RE	(b-B) Difference	sqrt(diag(V_b-V_B)) S.E.
GDP	.0001116	.0001913	-.0000798	.0000223
YEAR				
2001	1.406659	1.286329	.1203295	.0336888
2002	3.911752	3.653295	.2584566	.0723604
2003	2.66828	2.192903	.4753767	.1330918
2004	1.52752	.7561506	.771369	.2159612
2005	4.887629	3.813741	1.073888	.3006577
2006	5.255904	3.879378	1.376526	.3853877
2007	5.551774	3.795838	1.755936	.4916118
2008	5.965045	3.793292	2.171753	.6080285
2009	4.36565	1.922707	2.442943	.683954

b = consistent under Ho and Ha; obtained from xtreg
B = inconsistent under Ha, efficient under Ho; obtained from xtreg

Test: Ho: difference in coefficients not systematic

chi2(1) = (b-B)'[(V_b-V_B)^(-1)](b-B)
= 12.76
Prob>chi2 = 0.0004

采用FE