

第二讲

**简单截面数据
的经济计量方法
(一)**

- 数据：美国CPS(Current Population Survey)数据(简单截面观测数据)
- 研究目标：估计教育水平对小时工资的因果效应(教育回报或教育回报率)
- 研究思路：

- 假设总体模型： $y = \beta_0 + \beta_1 x + u$
- 总体模型：简单线性回归模型
 - y : 因变量(工资收入). x : 自变量(受教育程度)
- 数据是以随机方式从总体模型中抽取的，满足独立同分布

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

- 关注的问题：
 - 线性模型的含义
 - u 是什么
 - 模型参数的含义
 - 因果效应估计中的高斯-马尔可夫假定及意义

线性假设的含义

- 第一、 y 与 x 具有线性关系 $y = \beta_0 + \beta_1 x + u$
 - 样本体现的变量之间的线性关系在总体中是否显著，需检验
- 第二、 y 与 x 存在非线性关系 $y = \beta_0 + \beta_1 x^2 + u$
 - 变量之间的非线性关系可转化为线性关系

$$y = \beta_0 + \beta_1 g(x) + u, \quad z \equiv g(x), \quad y = \beta_0 + \beta_1 z + u$$

This model allows substantial flexibility, as the explanatory variables can appear in all kinds of nonlinear ways; the key restriction is that the model is linear in the β_j .

- 线性的含义是：不依赖于 y 和 x 的定义，关键是 y 线性于参数 β
 - 参数不是线性的，例如： $y = 1/(\beta_0 + \beta_1 x)$

u 是什么

- 简单线性回归模型体现的是变量之间的统计关系(非确定性关系)

$$y = \beta_0 + \beta_1 x + \textcircled{u} \quad \text{非确定性关系}$$

- u 为误差项(error term)或干扰项(disturbance)
 - 除 x 之外其他影响 y 的其他因素
 - y 中 x 无法解释的信息可能源于 u 的影响
- 导致 u 存在的原因:
 - 理论含糊: 理论不完备
 - 内在随机性: 即使列出所有因素也存在个体随机性
 - 数据欠缺: 影响因素的数据无法获得; 或者, 从数据收集成本等角度考虑, 列出不值得
 - 简单模型原则: 若简单模型足够以就把其他因素看做 u 吧!

模型参数的含义

- 目的：分析自变量对因变量的因果效应

- 称 β_1 为斜率参数，是否度量了因果效应？

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

$$y_j = \beta_0 + \beta_1 (x_i + \Delta x) + u_j$$

$$\Delta y = \beta_1 \Delta x + \Delta u$$

- 例： y 是工资、 x 是受教育程度(假设 x 为离散变量)
- i, j 是从总体模型中以随机抽样方式获得的,iid

- β_1 只有在： $\Delta u = 0$ 时为 x 对 y 的因果效应
 - β_1 度量因果效应的前提： u 中其他因素保持不变

- 例(第2章)：工资和受教育程度(wage1.txt)：利用一元线性回归模型，估计教育程度对小时工资的因果影响效应

```
> WAGE_lm<-lm(WAGE~EDUC,data=Data)
> summary(WAGE_lm)

Call:
lm(formula = WAGE ~ EDUC, data = Data)

Residuals:
    Min       1Q   Median       3Q      Max
-5.3396 -2.1501 -0.9674  1.1921 16.6085

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.90485    0.68497   -1.321    0.187
EDUC         0.54136    0.05325   10.167 <2e-16 ***
```

. reg WAGE EDU

Source	SS	df	MS	Number of obs	=	526
Model	1179.73205	1	1179.73205	F(1, 524)	=	103.36
Residual	5980.68226	524	11.4135158	Prob > F	=	0.0000
Total	7160.41431	525	13.6388844	R-squared	=	0.1648
				Adj R-squared	=	0.1632
				Root MSE	=	3.3784

WAGE	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
EDUC	.5413593	.053248	10.17	0.000	.4367534	.6459651
_cons	-.9048517	.6849678	-1.32	0.187	-2.250472	.4407687

- 问题：0.54作为因果效应估计具有可信性的前提？
 - u 中其他因素保持不变满足！
 - u 与 x 不相关！（对随机变量 u 和 x 的关系加以约束）
 - 计量强调这个的原因？——非实验的观测数据！

- 计量强调这个的原因？——非实验的观测数据！
 - 应用回归课程中：默认基于实验数据（ x 为非随机变量）

$$y_i = \beta_0 + \mathbf{x}_i\boldsymbol{\beta} + u_i, \quad i = 1, 2, \dots, N$$

$\{u_i: i = 1, 2, \dots, N\}$ are i.i.d. $E(u_i) = 0$ and $\text{Var}(u_i) = \sigma^2$.

- x 为非随机变量，默认排除了 u 与 x 相关的可能性
- 计量研究：基于观测数据，满足随机样本假设
 - 随机样本假设下对误差项的上述假定不再必要
 - u 原本就是IID的
 - 在模型中加入截距项后即可满足 $E(u) = 0$ 假设
 - 需要注意的是： u 是IID且没有对其是否与 x 相关做任何约束

- 例(第2章): 工资和受教育程度(wage1.txt): 利用一元线性回归模型, 度量教育程度对小时工资的因果影响效应

- 问题: 0.54因果效应估计具有可信性的前提?

- u 中其他因素保持不变满足!

```
> cor.test(Data$EXPER, Data$EDUC)

Pearson's product-moment correlation

data: Data$EXPER and Data$EDUC
t = -7.1868, df = 524, p-value = 2.295e-12
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.3754217 -0.2196734
sample estimates:
cor
-0.2995418
```

	EDUC	EXPER
EDUC	1.0000	
EXPER	-0.2995 0.0000	1.0000

- 教育程度与 u 中其他因素不相关不满足

- 结论: 0.54的因果效应估计不可靠!

- 处理方法:

- 假定 u 与 x 不相关(u 不是公共原因即干扰变量)
- 采用多元线性回归模型(对公共原因即干扰变量加以控制)




Figure 1.1: Causal structure of scenario 1, where condition C is a common cause of treatment T and mortality Y. Given this causal structure, treatment B is preferable.

如何提出假定： 计量研究中的总体模型

- u 的零条件均值假设, 是研究因果效应的重要前提假设
 - 可直接假定: $\text{Cov}(x, u) = 0$, 协方差等于0并不排除 u 与 x 可能存在非线性相关
 - 对给定 x 时 u 的期望做假定:
 - 零条件均值假定:

$$E(u | x) = E(u) \quad E(u | x) = E(u) = 0$$

The fact that $E(u | \mathbf{x}) = 0$ has the following important implications: (1) $E(u) = 0$; (2) u is uncorrelated with *any* function of $x_1, x_2, \dots, x_K$, and, in particular, u is uncorrelated with each of $x_1, x_2, \dots, x_K$.

- u 的零条件均值假设, 是研究因果效应的重要前提假设

- 零条件均值假定: $E(u | x) = E(u) = 0$

- 以 x 为条件对总体模型 $y = \beta_0 + \beta_1 x + u$ 求期望: $E(y|x) = \beta_0 + \beta_1 x$

称为总体回归函数(x 的线性函数)

- 即总体模型表述为: $y = E(y | \mathbf{x}) + u$

$$E(u | \mathbf{x}) = 0$$

In other words, we can always write y as its conditional expectation, $E(y | \mathbf{x})$, plus an **error term** or **disturbance term** that has *conditional* mean zero.

对 y 的影响: 系统影响部分+随机影响部分


- 进一步的理解: $E(y | \mathbf{x})$

$$E(y | x_1, x_2, \dots, x_K) = \mu(x_1, x_2, \dots, x_K)$$


可假设 μ 为 $\mathbf{x}$ 的线性函数, 即为 y 在 $1, \mathbf{x}$ 上的线性投影, 将复杂模型 μ 近似为一个简单的线性回归模型:

$$L(y | 1, \mathbf{x}) = \beta_0 + \beta_1 x_1 + \dots + \beta_K x_K = \beta_0 + \mathbf{x}\boldsymbol{\beta}$$

$\boldsymbol{\beta}$: 是 $\mathbf{x}$ 对 y 条件期望的边际变化而言的因果效应



■ 问题:



- 不论 x_i 的初始值如何，其变化对 y 的影响是相同，对许多研究是不现实的
 - 例：受教育年份增加带来的工资绝对量的增长通常不是一个常数
- 应用中可能关心变化百分比
 - 例：受教育年份增加带来的工资增长百分比可能是个常数
- 建立**对数模型** (第2、6章)

常见的对数模型

Model	Dependent Variable	Independent Variable	Interpretation of β_1
level-level	y	x	$\Delta y = \beta_1 \Delta x$
level-log	y	$\log(x)$	$\Delta y = (\beta_1/100)\% \Delta x$
log-level	$\log(y)$	x	$\% \Delta y = (100\beta_1) \Delta x$
log-log	$\log(y)$	$\log(x)$	$\% \Delta y = \beta_1 \% \Delta x$

- 半对数模型
 - 水平-对数模型、对数-水平模型
- 双对数模型

半对数模型参数的含义

- 水平-对数模型斜率参数的含义 (第6章)

$$y_i = \beta_0 + \beta_1 \log x_i + u_i$$

$$y_j = \beta_0 + \beta_1 [\log(x_i) + \Delta \log(x)] + u_j$$

$$\Delta y = \beta_1 \Delta \log(x)$$

因对数之差近似等于(在 x 的微小变化时)变化率: $\Delta \log x \approx (x_j - x_i) / x_i = \Delta x / x_i$,
记: $\Delta x / x_i = \Delta X$, $100\Delta X = \% \Delta X$

$$\Delta y = \beta_1 \Delta \log(x), \Delta y \approx \beta_1 \Delta X \quad \Delta y \approx \frac{\beta_1}{100} \% \Delta X$$

- u 中其他因素保持不变时, x 变化百分比变化引起 y 变动 $\beta_1/100$

半对数模型参数的含义

- 对数-水平模型斜率参数的含义 (更常见的半对数模型第2、6章)

$$\log y_i = \beta_0 + \beta_1 x_i + u_i, \log y_j = \beta_0 + \beta_1 (x_i + \Delta x) + u_j$$

$$\log y_j - \log y_i = \Delta \log y = \beta_1 \Delta x$$

- y 变化较小时对数之差近似等于变化率

$$\Delta \log y \approx (y_j - y_i) / y_i = \Delta y / y_i, \text{记: } \Delta y / y_i = \Delta Y, \text{ 则:}$$

$$100 \Delta \log y = (100 \beta_1) \Delta x \approx \% \Delta Y$$

- u 中其他因素保持不变时, x 变化一个单位引起的 y 变化百分比变动 $100\beta_1$
 - 称为 y 对 x 的**半弹性** (semi-elasticity) 系数: $\frac{\% \Delta Y}{\Delta x} = 100 \beta_1$
 - 对数变化是个相对变化, β_1 是对 x 绝对变化引起 y 的相对变化的测度

■ 例：教育回报率（每增加一年教育带来收入提高的百分比）：8.3%

$$\log(\hat{wage}) = 0.584 + 0.083 educ$$

```
> lgWAGE_lm<-lm(log(WAGE)~EDUC,data=Data)
> summary(lgWAGE_lm)
```

```
Call:
lm(formula = log(WAGE) ~ EDUC, data = Data)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-2.21158 -0.36393 -0.07263  0.29712  1.52339
```

```
Coefficients:
```

```
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.583773   0.097336   5.998 3.74e-09 ***
EDUC         0.082744   0.007567  10.935 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



```
Residual standard error: 0.4801 on 524 degrees of freedom
Multiple R-squared:  0.1858,    Adjusted R-squared:  0.1843
F-statistic: 119.6 on 1 and 524 DF,  p-value: < 2.2e-16
```

对数-水平模型对数据的拟合更好

```
. reg LNWAGE EDU
```

Source	SS	df	MS	Number of obs	=	526
Model	27.5606291	1	27.5606291	F(1, 524)	=	119.58
Residual	120.769121	524	.230475422	Prob > F	=	0.0000
				R-squared	=	0.1858
				Adj R-squared	=	0.1843
Total	148.32975	525	.282532857	Root MSE	=	.48008

LNWAGE	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
EDUC	.0827444	.0075667	10.94	0.000	.0678796	.0976092
_cons	.5837727	.0973358	6.00	0.000	.3925563	.7749891



双对数模型参数的含义

- 双对数模型(对数-对数模型)较常见

- 例：道格拉斯生产函数 $y = \beta_1 K^{\beta_2} H^{\beta_3} e^u$

$$\log y = \log \beta_1 + \beta_2 \log K + \beta_3 \log H + u$$

- 双对数模型斜率参数的含义

$$\log(y_i) = \beta_0 + \beta_1 \log x_i + u_i$$

$$\log(y_j) = \beta_0 + \beta_1 [\log(x_i) + \Delta \log(x)] + u_j$$

$$\Delta \log(y) = \beta_1 \Delta \log(x), \Delta Y \approx \beta_1 \Delta X \quad \longrightarrow \quad \% \Delta Y = \beta_1 \% \Delta X$$



- β_1 为 x 增加 1% 引起的 y 变化百分比变动
 - β_1 称为 y 对 x 的弹性系数: $\frac{\% \Delta Y}{\% \Delta X} = \beta_1$

- 双对数模型示例：杂志订阅数据的经济学研究 (R包自带, Journals.xlsx)
 - **price** (定价), **citations** (引文数), **subscribe** (订阅数)

title	publisher	society	price	pages	charpp	citations	foundingyear	subs	field
Asian-Pacific Economic Literature	Blackwell	no	123	440	3822	21	1986	14	General
South African Journal of Economic History	So Afr ec history assn	no	20	309	1782	22	1986	59	Economic History
Computational Economics	Kluwer	no	443	567	2924	22	1987	17	Specialized
MOCT-MOST Economic Policy in Transitional Economics	Kluwer	no	276	520	3234	22	1991	2	Area Studies
Journal of Socio-Economics	Elsevier	no	295	791	3024	24	1972	96	Interdisciplinary
Labour Economics	Elsevier	no	344	609	2967	24	1994	15	Labor
Environment and Development Economics	Cambridge Univ Pres	no	90	602	3185	24	1995	14	Development
Review of Radical Political Economics	Elsevier	no	242	665	2688	27	1968	202	Specialized
Economics of Planning	Kluwer	no	226	243	3010	28	1987	46	Area Studies
Metroeconomica	Blackwell	no	262	386	2501	30	1949	46	General
Journal of Consumer Policy	Kluwer	no	279	578	2200	32	1978	57	Consumer Econo
Real Estate Economics	MIT	no	165	749	2496	35	1973	125	Specialized
Development Policy Review	Blackwell	no	242	427	2731	36	1982	30	Development
Managerial and Decision Econ	Wiley	no	905	292	4472	37	1980	62	Management Scier
Journal of Empirical Finance	Elsevier	no	355	607	3053	37	1994	16	Finance
International Journal of Finance & Economics	Springer	no	375	351	4025	40	1996	17	Finance
Journal of Economics & Management Strategy	MIT Press	no	135	602	2394	42	1992	37	Management Scier
Atlantic Economic Journal	Intl Atlantic Ec. Soc.	no	171	447	3139	44	1972	148	General
Economic Development Quarterly	Sage	no	284	385	3318	47	1987	110	Development

```
data("Journals", package = "AER")
journals<-Journals[,c("subs","price")]
journals$citeprice<-Journals$price/Journals$citations
```

- 双对数模型示例：杂志订阅数据的经济学研究
 - 研究引文单价对订阅数的影响：利用弹性系数



```
> jour_lm<-lm(log(subs)~log(citeprice),data=journals)
> summary(jour_lm)

Call:
lm(formula = log(subs) ~ log(citeprice), data = journals)

Residuals:
    Min       1Q   Median       3Q      Max
-2.72478 -0.53609  0.03721  0.46619  1.84808

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    4.76621    0.05591   85.25  <2e-16 ***
log(citeprice) -0.53305    0.03561  -14.97  <2e-16 ***
```

计算订阅数对引文单价的
弹性系数：-0.53

. reg lnsubs lnciteprice

Source	SS	df	MS	Number of obs	=	180
Model	125.933995	1	125.933995	F(1, 178)	=	224.04
Residual	100.056056	178	.562112673	Prob > F	=	0.0000
				R-squared	=	0.5573
				Adj R-squared	=	0.5548
Total	225.990051	179	1.26251425	Root MSE	=	.74974

lnsubs	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
lnciteprice	-0.5330535	.0356132	-14.97	0.000	-.6033319	-.4627751
_cons	4.766212	.0559091	85.25	0.000	4.655882	4.876542

双对数模型的特点

- 效应值不随计量单位变化而变化，只体现在常数项上 (第6章)

$$y_i^* = c_1 y_i, x_i^* = c_2 x_i, \log y_i = \beta_0 + \beta_1 \log x_i$$

$$\log \frac{y_i^*}{c_1} = (\beta_0 + \beta_1 \log \frac{x_i^*}{c_2}),$$

$$\log y_i^* = (\beta_0 + \log c_1 - \beta_1 \log c_2) + \beta_1 \log x_i^*$$

- 采用双对数模型要根据分析需要，且例如 y 大于0
- 通常 $\log(y)$ 比 y 更接近模型对因变量分布的假定(正态分布)

■ 对数模型的预测问题(第6章)

$$\hat{\log y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_k x_k.$$

- 若预测值采用: $\hat{y} = \exp(\hat{\log y})$ 通常系统性地低估 y

- 原因:

$$\log y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u.$$

$$E(y|x) = \alpha_0 \exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k) \quad \alpha_0 = E[\exp(u)]$$

$$\hat{y} = \hat{\alpha}_0 \exp(\hat{\log y})$$

- α_0 的估计:

- 常见方法:

因为: 假设 u 服从期望等于0方差等于 σ^2 的正态分布, $\exp(u)$ 服从对数正态分布

$$\hat{\alpha}_0 = \frac{1}{n} \sum_{i=1}^n \exp(\hat{u}_i), \text{通常大于1}$$

$$\alpha_0 = E[\exp(u)] = \exp\left(\frac{1}{2} \sigma^2\right) > 1$$

作业: 依据经济学杂志订阅数据, 对比忽略和不忽略 α_0 的预测结果

因果效应估计中 高斯-马尔可夫假定及意义

假定与模型的参数估计

假定对模型参数性质的影响

假定与模型的评估

简单回归模型中的 高斯-马尔可夫假定 (第3章)

- **SLR1:** 线性于参数的总体模型

$$y = \beta_0 + \beta_1 x + u,$$

- **SLR2:** 随机抽样假定 (并确保解释变量的方差不等于0)

$$y_i = \beta_0 + \beta_1 x_i + u_i, i = 1, 2, \dots, n,$$

- **SLR3:** 零条件均值

$$E(u | x) = E(u) = 0$$

假定与模型的参数估计

■ 模型参数估计的出发点 (矩法估计):

$$E(u) = 0$$

$$\text{Cov}(x, u) = E(xu) = 0,$$



$$E(y - \beta_0 - \beta_1 x) = 0$$

$$E[x(y - \beta_0 - \beta_1 x)] = 0,$$

$$n^{-1} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0. \rightarrow \bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x},$$



$$n^{-1} \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0.$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

$$\sum_{i=1}^n x_i (y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i) = 0$$



$$\sum_{i=1}^n x_i (y_i - \bar{y}) = \hat{\beta}_1 \sum_{i=1}^n x_i (x_i - \bar{x}).$$

$$\sum_{i=1}^n x_i (x_i - \bar{x}) = \sum_{i=1}^n (x_i - \bar{x})^2 \text{ and } \sum_{i=1}^n x_i (y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

- 是x和y的样本协方差与x的样本方差之比
- x与y正相关, β 为正; 反之为负

■ 因为：

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

分母不能为零

■ 所以对数据的要求： x 的方差不等于0

■ 得到参数估计值后有： $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$,

■ 称为样本回归函数，是对总体回归函数的估计

$$E(y|x) = \beta_0 + \beta_1 x$$

■ x 带入回归函数计算的结果称为 y 的拟合值，记为 $\hat{y}$

■ 根据样本回归函数可计算：

$$\hat{u}_i = y_i - \hat{y}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i.$$


■ 称为残差

■ 注意：残差项不等同于误差项

A scatterplot of wage against education when educ_i = 12 for all i.



Fitted values and residuals.



- 与普通最小二乘法 (Ordinary Least Squares, OLS) 的联系
 - OLS估计是求残差平方和最小下的参数估计

$$\sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2,$$

对参数求偏导并令偏导数等于0

$$-2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0.$$

$$-2 \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0.$$

OLS的一阶条件

前述中参数估计的前提：零条件均值假设

$$E(u) = 0$$

$$\text{Cov}(x, u) = E(xu) = 0,$$

$$n^{-1} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0.$$

$$n^{-1} \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0.$$

$$\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0.$$

$$\sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0.$$

• OLS估计是默认零条件均值假设成立下的估计

假定对模型参数性质的影响

- 高斯-马尔可夫假定1-3保证OLS估计量的
 - 无偏性
 - 一致性
- 通过证明阐述高斯-马尔可夫假定对参数性质的影响

- 证明准备

- 因为：

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$



X的离差平方和

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(\beta_0 + \beta_1 x_i + u_i)}{s_x^2}$$

- 分子：

$$\begin{aligned} \sum_{i=1}^n (x_i - \bar{x})\beta_0 + \sum_{i=1}^n (x_i - \bar{x})\beta_1 x_i + \sum_{i=1}^n (x_i - \bar{x})u_i \\ = \beta_0 \sum_{i=1}^n (x_i - \bar{x}) + \beta_1 \sum_{i=1}^n (x_i - \bar{x})x_i + \sum_{i=1}^n (x_i - \bar{x})u_i. \end{aligned}$$

$$\sum_{i=1}^n (x_i - \bar{x})x_i = \sum_{i=1}^n (x_i - \bar{x})^2 = s_x^2.$$

- 有：

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{s_x^2} = \beta_1 + (1/s_x^2) \sum_{i=1}^n d_i u_i.$$

■ OLS估计量的无偏性证明: $E(\hat{\beta}_0) = \beta_0$, and $E(\hat{\beta}_1) = \beta_1$

- 所有期望均默认以 x 的样本值为条件的期望; d_i, s_x^2 均只是 x 的函数, 以 x 为条件下非随机

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{s_x^2} = \beta_1 + (1/s_x^2) \sum_{i=1}^n d_i u_i$$

$$\begin{aligned} E(\hat{\beta}_1) &= \beta_1 + E[(1/s_x^2) \sum_{i=1}^n d_i u_i] = \beta_1 + (1/s_x^2) \sum_{i=1}^n E(d_i u_i) \\ &= \beta_1 + (1/s_x^2) \sum_{i=1}^n d_i E(u_i) = \beta_1 + (1/s_x^2) \sum_{i=1}^n d_i \cdot 0 = \beta_1. \end{aligned}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = \beta_0 + \beta_1 \bar{x} + \bar{u} - \hat{\beta}_1 \bar{x} = \beta_0 + (\beta_1 - \hat{\beta}_1) \bar{x} + \bar{u}.$$

$$E(\hat{\beta}_0) = \beta_0 + E[(\beta_1 - \hat{\beta}_1) \bar{x}] + E(\bar{u}) = \beta_0 + E[(\beta_1 - \hat{\beta}_1)] \bar{x},$$

零条件均值假定下OLS估计是无偏估计

问题: 如果 u 与 x 相关确实是有偏估计吗?

零条件均值不满足下的效应估计

- u 与 x 相关下效应估计的讨论：采用迭代期望法则

law of iterated expectations (LIE)

There are also properties of the conditional expectation that have to do with the fact that $E(Y|X)$ is a function of X , say $E(Y|X) = \mu(X)$. Since X is a random variable, $\mu(X)$ is also a random variable. Furthermore, $\mu(X)$ has a probability distribution and therefore an expected value. Generally, the expected value of $\mu(X)$ could be very difficult to compute directly. The **law of iterated expectations** says that the expected value of $\mu(X)$ is simply equal to the expected value of Y . We write this as follows.

关于 x 函数

PROPERTY CE.4

$$E[E(Y|X)] = E(Y).$$

Suppose $Y = WAGE$ and $X = EDUC$, where $WAGE$ is measured in hours, and $EDUC$ is measured in years. Suppose the expected value of $WAGE$ given $EDUC$ is $E(WAGE|EDUC) = 4 + .60 EDUC$. Further, $E(EDUC) = 11.5$. Then, the law of iterated expectations implies that $E(WAGE) = E(4 + .60 EDUC) = 4 + .60 E(EDUC) = 4 + .60(11.5) = 10.90$, or \$10.90 an hour.

PROPERTY CE.4

$$E[E(Y|X)] = E(Y).$$

PROPERTY CE.4'

$$E(Y|X) = E[E(Y|X,Z)|X].$$

In other words, we can find $E(Y|X)$ in two steps. First, find $E(Y|X,Z)$ for any other random variable Z . Then, find the expected value of $E(Y|X,Z)$, conditional on X .

$$E(y | \mathbf{x}) = E[E(y | \mathbf{x}, \mathbf{z}) | \mathbf{x}]$$

or, defining $\mu_1(\mathbf{x}, \mathbf{z}) \equiv E(y | \mathbf{x}, \mathbf{z})$ and $\mu_2(\mathbf{x}) \equiv E(y | \mathbf{x})$,

$$\mu_2(\mathbf{x}) = E[\mu_1(\mathbf{x}, \mathbf{z}) | \mathbf{x}]$$

回归模型中，例：

$$E(y | x_1, x_2, z) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 z$$

利用CE. 4'



$$E(y | x_1, x_2) = E(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 z | x_1, x_2)$$

$$= \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 E(z | x_1, x_2)$$


$$E(z | x_1, x_2) = \delta_0 + \delta_1 x_1 + \delta_2 x_2$$

$$= \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 (\delta_0 + \delta_1 x_1 + \delta_2 x_2)$$

$$= (\beta_0 + \beta_3 \delta_0) + (\beta_1 + \beta_3 \delta_1) x_1 + (\beta_2 + \beta_3 \delta_2) x_2$$

假定对模型参数性质的影响

- 无偏性要求较严格，可考虑参数的一致性问题
- 格兰杰认为：“如果在 n 趋于无穷时还不能正确地得到参数的估计值，就不应该干这件事”（第5章）



当样本量增大时，能够让估计量接近真值！

$n \rightarrow \infty$ 有 $\text{var}(\text{估计量}) \rightarrow 0$

- OLS估计量的一致性证明:

$$\begin{aligned}\hat{\beta}_1 &= \left(\sum_{i=1}^n (x_i - \bar{x}) y_i \right) / \left(\sum_{i=1}^n (x_i - \bar{x})^2 \right) \\ &= \beta_1 + \left(n^{-1} \sum_{i=1}^n (x_i - \bar{x}) u_i \right) / \left(n^{-1} \sum_{i=1}^n (x_i - \bar{x})^2 \right).\end{aligned}$$

- 应用大数定律, 分子分母分别依概率收敛于总体的: $\text{Cov}(x, u)$ $\text{Var}(x)$

- 依斯卢茨基(Slutsky)定理:

$$\text{plim } \mathbf{g}(\mathbf{x}_N) = \mathbf{g}(\text{plim } \mathbf{x}_N)$$

$$\begin{aligned}\text{plim } \hat{\beta}_1 &= \beta_1 + \text{Cov}(x, u) / \text{Var}(x) \\ &= \beta_1, \text{ because } \text{Cov}(x, u) = 0\end{aligned}$$

- 渐近偏误(第5章)

只要求 x 与误差项线性不相关即可

- 渐近偏误, 记为 δ : $\text{plim } \hat{\beta}_1 - \beta_1 = \text{Cov}(x_1, u) / \text{Var}(x_1)$.

- 若 x 和 u 不相关, δ 为0, 无渐近偏误
- 若 x 和 u 正相关, δ 为正偏误; 反之则为负偏误
- 渐近偏误的大小因 u 无法观测而不能估计
- 可通过理论框架的不断完善减小渐近偏误

假定对模型参数性质的影响

- 问题：OLS具有无偏性和一致性是否就是理想的估计？
 - 还要了解它距真值的平均差距，即OLS估计量的方差


- **SLR4: 同方差性** (给定 x 的任何值, 误差都具有相同的方差, 常数方差) $\text{Var}(u|x) = \sigma^2$.

$$y = \beta_0 + \beta_1 x + u,$$




$$\text{Var}(u|x) = \text{Var}(y|x) \quad \text{Var}(y|x) = \sigma^2.$$

- 观察 y 的等方差性比对 u 做主观假定更直观



常数方差



异方差

$$\text{Var}(u|x) = E(u^2|x) - [E(u|x)]^2$$

$$E(u|x) = 0, \sigma^2 = E(u^2|x) \quad \sigma^2 = E(u^2) = \text{Var}(u)$$

零条件均值满足下, σ^2 也是 u 的无条件方差, 称为误差方差

- **SLR4**使OLS估计量的方差得以简化

- 因为：

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{s_x^2} = \beta_1 + (1/s_x^2) \sum_{i=1}^n d_i u_i.$$

- 所以：

$$\begin{aligned}\text{Var}(\hat{\beta}_1) &= (1/s_x^2)^2 \text{Var}\left(\sum_{i=1}^n d_i u_i\right) = (1/s_x^2)^2 \left(\sum_{i=1}^n d_i^2 \text{Var}(u_i)\right) \\ &= (1/s_x^2)^2 \left(\sum_{i=1}^n d_i^2 \sigma^2\right) \quad [\text{since } \text{Var}(u_i) = \sigma^2 \text{ for all } i] \\ &= \sigma^2 (1/s_x^2)^2 \left(\sum_{i=1}^n d_i^2\right) = \sigma^2 (1/s_x^2)^2 s_x^2 = \sigma^2 / s_x^2,\end{aligned}$$

随机抽样假定下 u_i 和 u_j 不相关，
和的方差等于方差的和

- OLS的方差随自变量变差增大而减小，自变量取值差异越大越好
- 因： $s_x^2 \approx n\sigma_x^2$ ，OLS的方差随样本量 n 增加而减少，样本量越大越好
- 问题：如何估计误差项方差 σ^2 ？

■ 估计误差方差 σ^2

■ 虽然： $\sigma^2 = E(u^2) = \text{Var}(u)$ ，但因无法观测 u ，无法计算 σ^2

■ 考虑：以残差的方差作为误差方差的估计

■ 估计的原因：残差不等同于误差

$$\hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i = (\beta_0 + \beta_1 x_i + u_i) - \hat{\beta}_0 - \hat{\beta}_1 x_i,$$

$$\hat{u}_i = u_i - (\hat{\beta}_0 - \beta_0) - (\hat{\beta}_1 - \beta_1)x_i. \quad \text{两者不等！但两者之差的期望等于零}$$

残差的方差 $n^{-1} \sum_{i=1}^n \hat{u}_i^2 = \text{SSR}/n.$ (SSR: Residual Sum of Squares)

■ 以上是方差的有偏估计：需考虑OLS一阶条件，残差只有 $n-2$ 个自由度：

$$\begin{aligned} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) &= 0. & \sum_{i=1}^n \hat{u}_i &= 0. \\ \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) &= 0. & \sum_{i=1}^n x_i \hat{u}_i &= 0. \end{aligned}$$

$$\hat{\sigma}^2 = \frac{1}{(n-2)} \sum_{i=1}^n \hat{u}_i^2 = \text{SSR}/(n-2).$$

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2},$$

回归标准误(Standard error of the regression, SER)

■ 可得到OLS估计量方差的估计： $\hat{\sigma}^2/s_x^2$

假定对模型参数性质的影响

- 总结:


- 假定1-假定3: 确保估计量的无偏性和一致性

- 估计是真值的最优线性无偏估计 (best linear unbiased estimator, BLUE)
 - 不需要再寻找其他无偏估计量, 没有一个会比OLS更好

- 假定4: 简化了估计量方差, 且 $Var(\hat{\beta}) \leq Var(\tilde{\beta})$

假定对模型评估的意义：模型拟合

- 拟合优度：回归线对样本的拟合程度



如果大部分的点落在回归线上，则拟合效果好， x 较好地解释了 y

- 度量方法：决定系数，涉及残差的问题

假定对模型评估的意义：模型拟合

- 残差的性质（第2章）：残差： $\hat{u}_i = y_i - \hat{y}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$.
- 根据OLS一阶条件：

$$\begin{array}{ccc} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0. & \rightarrow & \sum_{i=1}^n \hat{u}_i = 0. \\ \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0. & & \sum_{i=1}^n x_i \hat{u}_i = 0. \end{array}$$

- 且因： $y_i = \hat{y}_i + \hat{u}_i$ 有： $\bar{\hat{y}} = \bar{y}$.

- 有： x 与残差的样本协方差为0，意味着拟合值(x 的线性组合)与残差的样本协方差为0

假定对模型评估的意义：模型拟合

- 残差性质下，有：总平方和=解释平方和+残差平方和

$$SST = SSE + SSR.$$

$$SST \equiv \sum_{i=1}^n (y_i - \bar{y})^2.$$

$$SSE \equiv \sum_{i=1}^n (\hat{y}_i - \bar{y})^2.$$

$$SSR \equiv \sum_{i=1}^n \hat{u}_i^2.$$

$$\begin{aligned} \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n [(y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})]^2 \\ &= \sum_{i=1}^n [\hat{u}_i + (\hat{y}_i - \bar{y})]^2 \\ &= \sum_{i=1}^n \hat{u}_i^2 + 2 \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \\ &= SSR + 2 \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) + SSE. \end{aligned}$$

- 因： $\bar{\hat{y}} = \bar{y}$.
- 有：圆圈中为残差和拟合值的协方差，等于0

假定对模型评估的意义：模型拟合

- 基于残差的性质，构造决定系数 (coefficient of determination):

$$SST = SSE + SSR.$$

$$1 = SSE/SST + SSR/SST.$$

$$R^2 = SSE/SST = 1 - SSR/SST.$$

- 决定系数表明： y 的变差中被 x 线性解释的部分，不大于1，越接近于1，拟合优度越高

■ 例：教育回报率：8.3%


$$\log(\hat{wage}) = 0.584 + 0.083 \text{ educ}$$

. reg LNWAGE EDU

Source	SS	df	MS	Number of obs	=	526
Model	27.5606291	1	27.5606291	F(1, 524)	=	119.58
Residual	120.769121	524	.230475422	Prob > F	=	0.0000
				R-squared	=	0.1858
				Adj R-squared	=	0.1843
Total	148.32975	525	.282532857	Root MSE	=	.48008

LNWAGE	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
EDUC	.0827444	.0075667	10.94	0.000	.0678796 .0976092
_cons	.5837727	.0973358	6.00	0.000	.3925563 .7749891

拟合优度不高的原因？可能是对数-水平模型不合理，或还需引入其他自变量，等



```
> lgWAGE_lm<-lm(log(WAGE)~EDUC,data=Data)
> summary(lgWAGE_lm)
```

Call:
lm(formula = log(WAGE) ~ EDUC, data = Data)

Residuals:

Min	1Q	Median	3Q	Max
-2.21158	-0.36393	-0.07263	0.29712	1.52339

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.583773	0.097336	5.998	3.74e-09 ***
EDUC	0.082744	0.007567	10.935	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4801 on 524 degrees of freedom
Multiple R-squared: 0.1858, Adjusted R-squared: 0.1843
F-statistic: 119.6 on 1 and 524 DF, p-value: < 2.2e-16

假定对模型评估的意义： 总体斜率参数的假设检验

■ 总体参数的假设检验

$$y = \beta_0 + \beta_1 x + u,$$

- 问：为什么要对参数进行假设检验
- 答：模型是建立在 y 与 x 的线性假设下的，需检验 y 与 x 的线性关系在总体上是否显著，进而判断选择线性模型的合理性


■ 回归系数的显著性检验的原假设： $H_0: \beta_1 = 0$

- 基于 $\hat{\beta}_1$ 利用反证法，从概率角度做出推断
- 已知OLS估计量的期望和方差是不够的，需要知道其分布，才可利用 $\hat{\beta}_1$ 对 $H_0: \beta_1 = 0$ 进行假设检验
 - 需增加假定

假定对模型评估的意义： 总体斜率参数的假设检验

- **正态性假定** (第4章)：以 x 为条件的误差项 u ，服从均值为0方差为 σ^2 的正态分布
 - 因： $y = \beta_0 + \beta_1 x + u, \quad u \sim \text{Normal}(0, \sigma^2).$
 - 意味：以 x 为条件的 y 服从均值为 $E(y|x)$ ，方差为 σ^2 的正态分布

观察 y 的分布是否正态比
主观假定 u 正态更直观



假定对模型评估的意义： 总体斜率参数的假设检验

- 高斯马尔可夫SLR1至SLR4以及正态性假定，统称为经典线性模型假定(classical linear model assumption)
 - 该假定下的模型称为经典线性模型(CLM)
 - 说明：经典线性模型包括多元线性回归模型，其假设还包含与多元有关的假设(后面讲)

- 经典线性模型假设下以 x 为条件估计量的抽样分布为：

$$\hat{\beta}_1 \sim N(\beta_1, \text{Var}(\hat{\beta}_1))$$

因：估计量是误差的线性组合，且误差项独立同分布(正态分布)

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{s_x^2} = \beta_1 + (1/s_x^2) \sum_{i=1}^n d_i u_i$$

- 于是，有： $(\hat{\beta}_1 - \beta_1)/\text{sd}(\hat{\beta}_1) \sim N(0,1)$

- 一元模型OLS估计量的方差：

$$\text{Var}(\hat{\beta}_1) = \sigma^2/s_x^2,$$

- 一元模型误差项方差的估计：

$$\hat{\sigma}^2 = \frac{1}{(n-2)} \sum_{i=1}^n \hat{u}_i^2 = \text{SSR}/(n-2).$$

- 有： $(\hat{\beta}_1 - \beta_1)/\text{se}(\hat{\beta}_1) \sim t_{n-2}$

- sd (Standard deviation)和 se (Standard error)：前者分子为 σ^2 ，后者分子为 σ 的估计 $\hat{\sigma}^2$

- 最终：构造t统计量进行假设检验(或构造总体参数的置信区间)

- 注意：统计显著性和实际显著性的问题

- 说明：正态假定较为严苛；正态性假定不满足但大样本下OLS估计量近似正态分布，且估计量渐近有效

■ 例：教育回报率：8.3%

$$\log(\hat{wage}) = 0.584 + 0.083 \text{ educ}$$

```
> lgWAGE_lm<-lm(log(WAGE)~EDUC,data=Data)
> summary(lgWAGE_lm)
```

Call:

```
lm(formula = log(WAGE) ~ EDUC, data = Data)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-2.21158 -0.36393 -0.07263  0.29712  1.52339
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.583773    0.097336   5.998 3.74e-09 ***
EDUC         0.082744    0.007567  10.935 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



```
Residual standard error: 0.4801 on 524 degrees of freedom
Multiple R-squared:  0.1858,    Adjusted R-squared:  0.1843
F-statistic: 119.6 on 1 and 524 DF,  p-value: < 2.2e-16
```

```
> confint(lgWAGE_lm,level=0.95) #参数的区间估计
              2.5 %      97.5 %
(Intercept)  0.39255627 0.77498906
EDUC         0.06787958 0.09760915
```

. reg LNWAGE EDU

Source	SS	df	MS	Number of obs	=	526
Model	27.5606291	1	27.5606291	F(1, 524)	=	119.58
Residual	120.769121	524	.230475422	Prob > F	=	0.0000
				R-squared	=	0.1858
				Adj R-squared	=	0.1843
Total	148.32975	525	.282532857	Root MSE	=	.48008

LNWAGE	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
EDUC	.0827444	.0075667	10.94	0.000	.0678796 .0976092
_cons	.5837727	.0973358	6.00	0.000	.3925563 .7749891



```
educ<-seq(from=0,to=25,by=0.5)
lgWAGE_pred<-predict(lgWAGE_lm,level=0.95,interval="confidence", newdata=data.frame(EDUC=educ))
plot(log(WAGE)~EDUC,data=Data,xlim=c(0,25)) #因变量预测值的置信区间
lines(lgWAGE_pred[,1]~educ,col=1)
lines(lgWAGE_pred[,2]~educ,col=1,lty=2)
lines(lgWAGE_pred[,3]~educ,col=1,lty=2)
library("effects")
plot(allEffects(lgWAGE_lm, default.levels=50))
```

总结

- 问：在社会经济问题研究中
 - 高斯-马尔可夫假定哪些不易满足？
 - 无法满足带来的问题是什么？无法满足时应如何处理？
- 答：
 - 假定3： $E(u | x) = E(u) = 0$ 不易满足
 - 导致：估计量是有偏估计
 - 处理方法：控制其他因素，建立多元回归模型

总结

- 问：在社会经济问题研究中
 - 高斯-马尔可夫假定哪些不易满足？
 - 无法满足带来的问题是什么？无法满足时应如何处理？
- 答：
 - 假定4： $\text{Var}(u|x) = \sigma^2$. 不易满足(异方差)， u 的方差与 x 的取值有关
 - 例：收入与受教育程度
 - 导致：不影响参数估计的无偏性，但影响对OLS估计量方差的估计，使得回归系数显著性检验失效
 - 处理方法：加权最小二乘等

