

第五讲

**简单截面数据
的经济计量方法
(四)**

主要内容

- 模型中的内生解释变量：
 - 因不满足高斯马尔科假定，OLS对内生解释变量对因变量的因果偏效应估计是有偏和不一致的
- 出现内生变量的原因之一：自变量遗漏，解决途径
 - 对可以观测的遗漏变量：通过多元引入模型中
 - 对不可观测的遗漏变量
 - 代理变量法
 - 工具变量法
 - 两阶段最小二乘法

- 现实问题中存在大量影响因变量且与 x 相关但却无法观测的需控制的变量

- 例:

$$\log(\text{wage}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{abil} + u.$$

无法测度的

- 忽略无法观测的需控制的变量, 会导致模型设置不足产生的问题

- 合理的回归模型: $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K + \gamma q + v$

$$E(v | x_1, x_2, \dots, x_K, q) = 0$$

- q 为不可观测的变量, 关注自变量 x_k 的效应估计

- 忽略 q : $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K + u$ $u \equiv \gamma q + v$

- 且假设:

$$q = \delta_0 + \delta_1 x_1 + \cdots + \delta_K x_K + r$$

- 将 q 代回合理的回归模型, 变换得到忽略 q 时的回归模型(变量遗漏):

$$y = (\beta_0 + \gamma \delta_0) + (\beta_1 + \gamma \delta_1)x_1 + (\beta_2 + \gamma \delta_2)x_2 + \cdots + (\beta_K + \gamma \delta_K)x_K + v + \gamma r$$

- 讨论一致性: q 与 x_k 的相关性将导致不一致的估计


$$\text{plim } \hat{\beta}_K = \beta_K + \gamma [\text{Cov}(x_K, q) / \text{Var}(x_K)]$$

假设除 x_K 之外的其他 x_i 的 $\delta_i = 0$

什么是代理变量

- 处理方法：找到无法观测变量的代理变量 (第9章)
 - 代理变量 (Proxy variable)：某种与研究分析中试图控制而又无法观测的变量相关的变量
 - 例：
$$\log(\text{wage}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{abil} + u.$$
 - 能力的代理变量：IQ
 - $\log(\text{wage})$ 对 educ , exper , IQ 回归，得到的 β_1 称为遗漏变量问题的植入解 (plug-in solution to the omitted variables problem)

无法观测的



- 并非左图所示的简单的变量替换，需关注：
 - 如何引入代理变量 IQ
 - 植入解在怎样的条件下是 β_1 的一致性估计

- 代理变量：以三个自变量为例

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3^* + u.$$

无法观测的

- 例： x_3^* 为能力 (无法观测)
- 代理变量 **应** 与无法观测的变量有如下关系：例： x_3 为 IQ, 是 x_3^* 能力的代理变量

$$x_3^* = \delta_0 + \delta_3 x_3 + v_3$$

代理变量

- δ_3 : 反应了代理变量和原变量的相关程度和方向
- v_3 意味着代理变量与原变量不完全相关; v_3 满足零条件均值假设;
- 拓展到一般情况:
 - q 为不可观测的需控制的变量
 - z 是 q 的代理变量

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K + \gamma q + v$$

$$E(v | x_1, x_2, \dots, x_K, q) = 0$$


$$q = \theta_0 + \theta_1 z + r \quad E(r) = 0 \text{ and } \text{Cov}(z, r) = 0$$

- 回归模型为:

$$y = (\beta_0 + \gamma \theta_0) + \beta_1 x_1 + \cdots + \beta_K x_K + \gamma \theta_1 z + (\gamma r + v)$$

- $\gamma \theta_1 \neq \gamma$, 故不是简单的 **变量替换** (见图)。 $\gamma \theta_1$ 表征了 z 对 y 的影响, 也具有实际意义

代理变量的引入形式



此时的植入解是 β 的一致性估计, 称 z 是 q 的好的代理变量! Why?

好的代理变量的特点:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K + \gamma q + v$$

$$E(v | x_1, x_2, \dots, x_K, q) = 0$$

$$q = \theta_0 + \theta_1 z + r \quad E(r) = 0 \text{ and } \text{Cov}(z, r) = 0$$

$$y = (\beta_0 + \gamma \theta_0) + \beta_1 x_1 + \cdots + \beta_K x_K + \gamma \theta_1 z + (\gamma r + v)$$

特点1: 控制了 $\mathbf{x}$ 、 q 后, z 与 y (期望) 不相关:

$$E(y | \mathbf{x}, q, z) = E(y | \mathbf{x}, q)$$

■ z 只通过 q 对 y 产生影响 (IQ 通过影响能力而影响工资)


特点2: 控制了 z (IQ) 后, q (能力) 与 $\mathbf{x}$ (每个) 零相关:

$$E(q | \mathbf{x}, z) = E(q | z) = \theta_1 z$$

$$q = \theta_0 + \theta_1 z + r \quad \longrightarrow \quad \text{Cov}(x_j, r) = 0,$$

z 与 q 高度相关 (z 已充分解释了 q 无需 $\mathbf{x}$, 即误差项 r 与 $\mathbf{x}$ 零相关)

保证 β 估计的一致性



- 如果 z 不是 q 的好的代理变量:

- 不满足: $E(q | \mathbf{x}, z) = E(q | z) = \theta_1 z$

- 即: $q = \theta_0 + \rho_1 x_1 + \cdots + \rho_K x_K + \theta_1 z + r$

- 将 q 带入:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K + \gamma q + v$$

$$E(v | x_1, x_2, \dots, x_K, q) = 0$$

- β_j 的一致性讨论: $\text{plim } \hat{\beta}_j = \beta_j + \gamma \rho_j$ 因 $\rho_j \neq 0$, 是不一致的估计

- 好的代理变量会减少渐近方差 (与遗漏 q 时相比)

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K + \gamma q + v$$

$$E(v | x_1, x_2, \dots, x_K, q) = 0$$

遗漏 q 时的误差项

$$q = \theta_0 + \theta_1 z + r$$

$$E(r) = 0 \text{ and } \text{Cov}(z, r) = 0$$

$$y = (\beta_0 + \gamma \theta_0) + \beta_1 x_1 + \cdots + \beta_K x_K + \gamma \theta_1 z + (\gamma r + v)$$

引入代理变量 z 时的误差项

$$\text{Var}(\gamma r + v) < \text{Var}(\gamma q + v) \text{ 因为: } \text{Var}(r) < \text{Var}(q)$$

如何选择代理变量

- 因无法观察到 q , 代理变量的选择需根据研究问题确定
 - 例: IQ作为能力的代理变量
- 可用滞后因变量作为代理变量反映“惯性”影响
 - 例:

$$crime = \beta_0 + \beta_1 unem + \beta_2 expend + \beta_3 crime_{-1} + u_i$$

- 导致城市犯罪的因素有很多, 如失业率, 人均执法支出等。同时也有许多无法观测且与失业率和执法支出相关的因素, 如人口迁移等无法观测的变量; 这些因素会体现在对以往犯罪率的影响上
- 将因变量的滞后放入模型加以控制对政策分析很有用 (动态面板分析)

代理变量的类似问题：测量误差

- 测量误差
 - 因变量中的测量误差
 - 研究：存在测量误差的因变量是如何受到其他变量的影响
 - 自变量中的测量误差
 - 研究：存在测量误差的自变量是如何影响因变量的

因变量的测量误差问题

- 因变量中的测量误差 (9.4节)：如研究家庭年收入受哪些因素影响

实际值

$$y^* = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u, \text{ (真实值模型)}$$

- 假定： u 零均值且与解释变量无关
- 测量误差：


测量误差

$$e_0 = y - y^*$$

测量值

$$y^* = y - e_0$$

- 通常默认：**经典变量误差** (classical errors-in-variables, **CEV**) 假定成立
 - e_0 零均值
 - $\text{Cov}(e_0, y) \neq 0$ (测量导致), $\text{Cov}(e_0, y^*) = 0$



■ 估计量的性质：

- 若测量误差 e_0 与 x_i 无关(误差是纯随机误差)，估计量是一致的；否则(如年收入误差与家庭属性有关)是不一致的
- 因变量的测量误差导致误差项的方差增大，使估计量的方差增大
 - 一般测量误差 e_0 与 u 不相关，则：

$$\text{Var}(u + e_0) = \sigma_u^2 + \sigma_0^2 > \sigma_u^2$$

总结：依据测量值建模，通常OLS估计是一致的，但会增大估计量的方差！！

自变量的测量误差问题

- 自变量中的测量误差 (9.4节):

(真实值模型)

测量误差

$$y = \beta_0 + \beta_1 x_1^* + u,$$

实际值

↑ 代入

$$e_1 = x_1 - x_1^*$$

测量值

(测量值模型)

$$y = \beta_0 + \beta_1 x_1 + (u - \beta_1 e_1).$$

- 假设: e_1 零均值; u 因与实际值 x_1^* 无关, 也与测量变量 x_1 无关
- 问: 用 x_1 代替 x_1^* 得到的估计会怎样?
 - 答: 有两种情况

- 计量经济学文献对测量误差有两种假设: $e_1 = x_1 - x_1^*$

- 假定1: 测量误差 e_1 与测量值 x_1 无关 $\text{Cov}(x_1, e_1) = 0$.

- 测量误差 e_1 源于实际值 x_1^*

- 例: 血压测量中的误差, 血压仪准确, 误差源于被测量者自身

- 表述为:

$$\begin{aligned} \text{cov}(x_1^*, e_1) &= E[x_1^* e_1] = E[(x_1 - e_1) e_1] \\ &= -E(e_1^2) = -\sigma_{e_1}^2 \neq 0 \end{aligned}$$

- 因误差项与 x_1 无关

$$y = \beta_0 + \beta_1 x_1 + (u - \beta_1 e_1)$$

零均值且与自变量不相关

- 所得估计是一致的
- OLS性质良好, 但通常不是讨论的重点

- 假定2: 测量误差 e_1 与实际 x_1^* 无关, 与测量值 x_1 有关

- 例: 血压测量中血压仪精度导致的误差

- 满足经典变量误差假定 (CEV假定)

$$e_1 = x_1 - x_1^* \quad x_1 = x_1^* + e_1,$$

$$\text{Cov}(x_1^*, e_1) = 0. \quad \text{Cov}(x_1, e_1) = E(x_1 e_1) = E(x_1^* e_1) + E(e_1^2) = 0 + \sigma_{e_1}^2 = \sigma_{e_1}^2$$

- 模型的误差项与解释变量相关, 估计量是不一致的

$$y = \beta_0 + \beta_1 x_1 + (u - \beta_1 e_1).$$

$$\begin{aligned} \text{Cov}(x_1, u - \beta_1 e_1) &= E[x_1(u - \beta_1 e_1)] - E(x_1)E(u - \beta_1 e_1) \\ &= E(x_1 u - x_1 \beta_1 e_1) - 0 \\ &= E(x_1 u) - \beta_1 E(x_1 e_1) \\ &= -\beta_1 \text{Cov}(x_1, e_1) \end{aligned}$$

$$\text{Cov}(x_1, u - \beta_1 e_1) = -\beta_1 \text{Cov}(x_1, e_1) = -\beta_1 \sigma_{e_1}^2.$$

- 测量误差存在非0方差导致测量值内生
- 自变量的测量误差是导致其内生性的另一个原因

- x_1 与 e_1 相关导致 OLS 估计的一致性偏误:

$$y = \beta_0 + \beta_1 x_1 + (u - \beta_1 e_1).$$

$$\text{Cov}(x_1, u - \beta_1 e_1) = -\beta_1 \text{Cov}(x_1, e_1) = -\beta_1 \sigma_{e_1}^2.$$

$$\begin{aligned} \text{plim}(\hat{\beta}_1) &= \beta_1 + \frac{\text{Cov}(x_1, u - \beta_1 e_1)}{\text{Var}(x_1)} && x_1 = x_1^* + e_1, \\ &= \beta_1 - \frac{\beta_1 \sigma_{e_1}^2}{\sigma_{x_1^*}^2 + \sigma_{e_1}^2} = \beta_1 \left(1 - \frac{\sigma_{e_1}^2}{\sigma_{x_1^*}^2 + \sigma_{e_1}^2} \right) && \text{Var}(x_1) = \text{Var}(x_1^*) + \text{Var}(e_1). \\ &= \beta_1 \left(\frac{\sigma_{x_1^*}^2}{\sigma_{x_1^*}^2 + \sigma_{e_1}^2} \right), && \text{一致性偏误} \end{aligned}$$

- 括号小于1，估计量的绝对值会偏小(向零偏误)
- 取决于 x_1^* 的方差。若相对于 e_1 的方差大很多，则偏误很小，用测量值替代原变量，测量误差不会导致很大的一致性偏误

- 自变量测量误差对估计量方差的影响

$$y = \beta_0 + \beta_1 x_1 + (u - \beta_1 e_1)$$

$$\text{Var}(u - \beta_1 e_1) = \sigma_u^2 + \beta_1^2 \sigma_{e_1}^2$$

总结：CEV假设下，依据测量值建模，OLS估计存在向零的不一致性偏误，且会增大估计量的方差！！

- 测量误差会提高估计量方差

- 例9.7：研究家庭收入对大学GPA的影响

$$\text{colGPA} = \beta_0 + \beta_1 \text{faminc}^* + \beta_2 \text{hsGPA} + \beta_3 \text{SAT} + u,$$

$$\text{faminc} = \text{faminc}^* + e_1$$

- 在CEV假设下：faminc为内生变量， β_1 的OLS估计存在向零偏误
 - 存在测量误差对 β_1 做t检验时，因误差项方差大将不易拒绝 H_0

工具变量法

- 不是任何问题都能找到合适的代理变量, 另一策略: 将无法观测的变量留在误差项

- 例:

$$\log(\text{wage}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{abil} + e,$$



将无法观测的需控制的变量
留在误差项中, 不予考虑!

无法观测的

$$\log(\text{wage}) = \beta_0 + \beta_1 \text{educ} + u,$$

- 放弃OLS估计, 用一种“承认”存在遗漏变量的估计方法:
 - 工具变量法 (instrumental variable, **IV**) (第15章)

- 对简单回归模型:


$$y = \beta_0 + \beta_1 x + u,$$

$$\log(\text{wage}) = \beta_0 + \beta_1 \text{educ} + u,$$

- 存在遗漏自变量: $\text{Cov}(x, u) \neq 0$.
- 得到一致性估计的处理方法: 找内生变量 x (例: educ)的**工具变量**, 切断 $u \rightarrow x \rightarrow y$ 的路径

- 工具变量IV(记为 z)需满足:

- IV(z)与内生变量 x 相关: $\text{Cov}(z, x) \neq 0$.
 - 称为具有**工具相关性**(instrument relevance)
- IV(z)在方程中是外生的, 与 u 不相关: $\text{Cov}(z, u) = 0$;
 - 称为具有**工具外生性**(instrument exogeneity)
- IV(z)具有**排除性约束**(exclusion restrictions)
 - IV排除在原方程之外;
 - 排除在原方程意味着: IV只通过内生变量 x 作用于被解释变量, 没有(排除了)其他影响途径



- 工具变量举例：可从排除性约束角度找IV (通常工具外生性的判断比较困难)

- 例：

$$\log(\text{wage}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{abil} + e, \Rightarrow \log(\text{wage}) = \beta_0 + \beta_1 \text{educ} + u,$$

- educ的IV：与educ相关与能力不相关，如父母的教育程度？兄弟姐妹数？
- 再例：研究学生成绩的影响因素，仅考虑逃课次数(skipped)

$$\text{score} = \beta_0 + \beta_1 \text{skipped} + u,$$

- skipped很可能与 u 中的其他因素相关，如自学能力
 - skipped的IV：与skipped相关，与自学能力等不相关。如：宿舍与学校的距离
- 工具变量与代理变量：
 - 共同点：相关性和排除性约束
 - 不同点：工具变量针对内生解释变量；代理变量通常针对希望控制的变量

工具变量法

- 如何考察一个变量是否可以作为IV
 - 是否与 u 不相关(工具外生性): 没有有效的技术手段, 通常依据经济问题本身判断
 - 是否与 x 相关(工具相关性): 估计 x 与 z 的简单回归
 - 建立模型:

$$x = \pi_0 + \pi_1 z + v.$$

- 原假设:

$$H_0: \pi_1 = 0$$

- 如果拒绝原假设, 则认为 z 与 x 有关, 具有工具相关性

一元回归模型中的IV估计

- IV的作用：克服变量遗漏导致的问题，通过IV得到 β_1 的一致性估计
- 一元模型中： $y = \beta_0 + \beta_1 x + u$
 - 为估计 β_1 ，首先计算IV(z)与 y 的协方差

$$\begin{aligned}\text{Cov}(z, y) &= E(z y) - E(z)E(y) \\&= E(z \beta_0 + z \beta_1 x + z u) - E(z)E(y) \\&= \beta_0 E(z) + \beta_1 E(z x) + E(z u) - E(z)E(y) \\&= \beta_0 E(z) + \beta_1 \text{Cov}(x, z) + \beta_1 E(z)E(x) + \text{Cov}(z, u) + \cancel{E(z)E(u)} - E(z)E(y) \\&= \beta_1 \text{Cov}(x, z) + \text{Cov}(z, u) + E(z)(\beta_0 + \beta_1 E(x) - E(y)) \\&= \beta_1 \text{Cov}(x, z) + \text{Cov}(z, u) + E(z)(\beta_0 + \beta_1 E(x) - \beta_0 - \beta_1 E(x)) \\&= \beta_1 \text{Cov}(x, z) + \text{Cov}(z, u)\end{aligned}$$

一元回归模型中的IV估计

- 在IV假定下:

- 有:

$$\beta_1 = \frac{\text{Cov}(z, y)}{\text{Cov}(z, x)}$$



$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^n (z_i - \bar{z})(x_i - \bar{x})}$$

β_1 的IV估计量

$$\text{Cov}(z, y) = \beta_1 \text{Cov}(z, x) + \text{Cov}(z, u)$$

- 可见:

- x 与 z 的协方差**不能为0**, 即 x 与 z 相关
- 当 x 外生时可作为自身的IV(z), IV估计等同于OLS估计

$$y = \beta_0 + \beta_1 x + u,$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

- 大样本IV估计量的一致性

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^n (z_i - \bar{z})(x_i - \bar{x})}.$$

- 参照：

$$\hat{\beta}_1 = \left(\sum_{i=1}^n (x_{i1} - \bar{x}_1)y_i \right) / \left(\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2 \right)$$

- 有：

$$= \beta_1 + \left(n^{-1} \sum_{i=1}^n (x_{i1} - \bar{x}_1)u_i \right) / \left(n^{-1} \sum_{i=1}^n (x_{i1} - \bar{x}_1)^2 \right).$$

$$\hat{\beta}_1 = \beta_1 + \frac{n^{-1} \sum_{i=1}^n (z_i - \bar{z})u_i}{n^{-1} \sum_{i=1}^n (x_i - \bar{x})(z_i - \bar{z})}$$



$$\text{plim } \hat{\beta}_1 = \beta_1 + \frac{\text{Corr}(z, u)}{\text{Corr}(z, x)} \cdot \frac{\sigma_u}{\sigma_x},$$

IV估计的一致性渐进偏误

z与u不在线性相关时： $\beta_1: \text{plim}(\hat{\beta}_1) = \beta_1,$

- 大样本IV估计量的方差

- 增加同方差假设:

- $\hat{\beta}_1$ 的IV估计量的渐近方差为:

给定IV下的

$$E(u^2|z) = \sigma^2 = \text{Var}(u).$$

$$\hat{\beta}_1 = \beta_1 + \frac{n^{-1} \sum_{i=1}^n (z_i - \bar{z}) u_i}{n^{-1} \sum_{i=1}^n (x_i - \bar{x})(z_i - \bar{z})}$$



$$\begin{aligned} \text{Var}(\hat{\beta}_1) &= \frac{n^{-2} \sigma^2 \sum_{i=1}^n (z_i - \bar{z})^2}{(\text{Cov}(x, z))^2} = \frac{\sigma^2 \sigma_z^2}{n \sigma_x^2 \sigma_z^2 \left(\frac{\text{Cov}(x, z)}{\sigma_x \sigma_z} \right)^2} \\ &= \frac{\sigma^2}{n \sigma_x^2 \rho_{x,z}^2} \end{aligned}$$

估计

$$\frac{\hat{\sigma}^2}{n \hat{\sigma}_x^2 \hat{\rho}_{x,z}^2}, \quad \hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{u}_i^2,$$

估计

$$\frac{\hat{\sigma}^2}{\text{SST}_x \hat{R}_{x,z}^2},$$

IV估计残差

与一元中OLS估计量的方差有怎样的不同?

IV估计量与OLS估计量的对比

- IV估计量与OLS估计量的对比：估计量的一致性渐近偏误

- IV估计量的概率极限：

- OLS估计量的概率极限：

$$\text{plim } \hat{\beta}_1 = \beta_1 + \frac{\text{Corr}(z, u)}{\text{Corr}(z, x)} \cdot \frac{\sigma_u}{\sigma_x},$$

$$\begin{aligned} \text{plim } \hat{\beta}_1 &= \beta_1 + \text{Cov}(x, u) / \text{Var}(x) \\ &= \beta_1, \text{ because } \text{Cov}(x, u) = 0 \end{aligned}$$

$$\text{plim } \hat{\beta}_1 = \beta_1 + \text{Corr}(x, u) \cdot \frac{\sigma_u}{\sigma_x}.$$

- 只有在：

$$\text{Corr}(z, u) / \text{Corr}(z, x) < \text{Corr}(x, u).$$

- IV的渐近偏误才小于OLS的渐近偏误

- 要求：

- 选择的IV：IV的外生性(与 u 相关性弱)，会减少渐近偏误

- 选择的IV：IV的工具相关性(非弱工具weak instruments)，会减少渐近偏误

IV估计量与OLS估计量的对比

- IV估计量与OLS估计量的对比：估计量的渐近方差
 - IV估计量： $\sigma^2 / (\text{SST}_x \cdot R_{x,z}^2)$
 - OLS估计量： σ^2 / SST_x
- IV渐近方差总是大于OLS
 - 当 x 与 z 弱相关，IV渐近方差比OLS大的多
 - 当 x 与 z 的相关性越强，IV渐近方差会越小
 - 选择的IV要与原变量有较强的相关性

■ 一元回归模型的IV示例 (例15.1 MROZ.TXT)

- 目标：分析已婚职业女性的教育回报率：采用OLS估计

```
> Data<-read.table(file="mroz.txt",header=TRUE,sep="")
> summary(morз_lm<-lm(LWAGE~EDUC,data=Data))

Call:
lm(formula = LWAGE ~ EDUC, data = Data)

Residuals:
    Min       1Q   Median       3Q      Max
-3.10256 -0.31473  0.06434  0.40081  2.10029

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.1852     0.1852  -1.000   0.318
EDUC          0.1086     0.0144   7.545 2.76e-13 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.68 on 426 degrees of freedom
(325 observations deleted due to missingness)
Multiple R-squared:  0.1179,    Adjusted R-squared:  0.1158
F-statistic: 56.93 on 1 and 426 DF,  p-value: 2.761e-13
```

- 解决方案：找educ的IV
- fatheduc与educ有较强相关(工具相关性, 这里不检验工具外生性)

$$\log(\text{wage}) = \beta_0 + \beta_1 \text{educ} + u.$$

- 存在能力遗漏, OLS估计为有偏估计
- OLS估计偏高 $E(\tilde{\beta}_1) - \beta_1 = \beta_2 \tilde{\delta}_1$

	$\text{Corr}(x_1, x_2) > 0$	$\text{Corr}(x_1, x_2) < 0$
$\beta_2 > 0$	positive bias	negative bias
$\beta_2 < 0$	negative bias	positive bias

```
lm(formula = EDUC ~ FATHEDUC, data = Data)

Residuals:
    Min       1Q   Median       3Q      Max
-8.1881 -1.1881  0.2240  0.8119  6.3537

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  9.79901     0.19854  49.36  <2e-16 ***
FATHEDUC     0.28243     0.02089  13.52  <2e-16 ***
---
```

```
> summary(morз_iv<-ivreg(LWAGE~EDUC|FATHEDUC,data=Data)) #IV工具变量法
```

Call:

```
ivreg(formula = LWAGE ~ EDUC | FATHEDUC, data = Data)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-3.0870 -0.3393  0.0525  0.4042  2.0677
```

Coefficients:

```
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.44110    0.44610   0.989   0.3233
EDUC         0.05917    0.03514   1.684   0.0929
```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.6894 on 426 degrees of freedom
Multiple R-Squared: 0.09344,    Adjusted R-squared: 0.09131
Wald test: 2.835 on 1 and 426 DF, p-value: 0.09294
```

```
> summary(morз_tsls<-tsls(LWAGE~EDUC,instruments=~FATHEDUC,data=Data))
```

2SLS Estimates

Model Formula: LWAGE ~ EDUC

Instruments: ~FATHEDUC

Residuals:

```
      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-3.0870 -0.3393  0.0525  0.0000  0.4042  2.0680
```

```
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.44110339 0.44610177 0.98880 0.323325
EDUC         0.05917348 0.03514177 1.68385 0.092943
```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.6893899 on 426 degrees of freedom
```

```
. ivregress 2sls LWAGE (EDU=FATHEDUC)
```

```
Instrumental variables (2SLS) regression      Number of obs   =       428
Wald chi2(1)                                =       2.85
Prob > chi2                                  =      0.0914
R-squared                                    =      0.0934
Root MSE                                    =      .68778
```

LWAGE	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
EDUC	.0591735	.0350596	1.69	0.091	-.009542	.127889
_cons	.4411034	.4450583	0.99	0.322	-.4311948	1.313402

Instrumented: EDUC

Instruments: FATHEDUC

```
> Data<-read.table(file="mroz.txt",header=TRUE,sep="")
> summary(morз_lm<-lm(LWAGE~EDUC,data=Data))
```

Call:

```
lm(formula = LWAGE ~ EDUC, data = Data)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-3.10256 -0.31473  0.06434  0.40081  2.10029
```

Coefficients:

```
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.1852    0.1852   -1.000   0.318
EDUC         0.1086    0.0144   7.545 2.76e-13 ***
```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.68 on 426 degrees of freedom
(325 observations deleted due to missingness)
```

```
Multiple R-squared:  0.1179,    Adjusted R-squared:  0.1158
F-statistic: 56.93 on 1 and 426 DF, p-value: 2.761e-13
```

• OLS估计还是IV估计?

• OLS不一致(偏高), 但估计量的方差较小

• 好的IV下, IV估计一致性偏误小, 但估计量的方差较大

• 为什么是TSLS(2SLS)?

多元回归模型中的IV

- 以两元为例：用新的记法区别内生和外生变量

称为结构方程
(structural equation)

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u_1$$

结构误差

- β_1, β_2 称为 **结构参数**； z_1 为外生变量， y_2 为内生变量 (u_1 中包含与 y_2 相关的遗漏变量)，且 $E(u_1) = 0$.

- 例：
$$\log(\text{wage}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + u_1$$

- 假设：educ 为内生变量，exper 为外生变量
- 模型中 β_1 的 OLS 估计是不一致的

- 处理方法：寻找 y_2 的IV

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u_1.$$

- 问： z_1 可作为 y_2 的IV吗？答：不能
- 原因：已出现在模型中的外生变量(z_1)不能作为内生变量(y_2)的IV，即使 z_1 与 y_2 相关与 u_1 不相关(z_1 不满足排除性约束)
- 处理方法：有方程外的变量 z_2 满足：

- 条件一： z_2 与 y_2 相关，且在控制 z_1 的条件下相关：

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + v_2,$$

$$E(v_2) = 0, \text{Cov}(z_1, v_2) = 0, \text{ and } \text{Cov}(z_2, v_2) = 0,$$

$$H_1: \pi_2 \neq 0.$$

选择 y_2 的IV变量时可首先建立该模型，并利用OLS估计检验 H_0

- 条件二： $E(u_1) = 0, \text{Cov}(z_1, u_1) = 0, \text{ and } \text{Cov}(z_2, u_1) = 0,$

z_1 、 z_2 是否与 u 相关，只能依靠对问题的理解

多元回归模型中的IV估计

- 由：
- 有：

$$E(u_1) = 0, \text{Cov}(z_1, u_1) = 0, \text{ and } \text{Cov}(z_2, u_1) = 0. \longrightarrow E(z_1 u_1) = E(z_2 u_1) = 0,$$

$$\sum_{i=1}^n (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) = 0$$

$$\sum_{i=1}^n z_{i1} (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) = 0$$

$$\sum_{i=1}^n z_{i2} (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) = 0.$$

- 由此得到结构参数的IV估计

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u_1.$$

- 若 y_2 是外生，其IV即自身，即 $z_2 = y_2$ ，则IV估计量等于OLS估计量

多元回归模型中的IV

- 更一般的情况

- 结构方程:

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \dots + \beta_k z_{k-1} + u_1,$$

- 其中:

$$E(u_1) = 0, \text{Cov}(z_j, u_1) = 0, j = 1, \dots, k.$$

- 结构方程右边的每个变量都应有各自的IV (外生解释变量的IV是自身)

- 找到内生解释变量的IV:

$$y_2 = \pi_0 + \pi_1 z_1 + \dots + \pi_{k-1} z_{k-1} + \pi_k z_k + v_2,$$

约简型方程 (reduced form equation) :
通过外生变量表示内生变量

- $H_1: \pi_k \neq 0.$

- 将内生变量 x_K 直接替换为IV会怎样？ $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K + u$ x_K 为内生解释变量

$$E(u) = 0, \quad \text{Cov}(x_j, u) = 0, \quad j = 1, 2, \dots, K-1$$

- 有外生变量 z_1 : $\text{Cov}(z_1, u) = 0$

- x_K 的约简型方程:

$$x_K = \delta_0 + \delta_1 x_1 + \delta_2 x_2 + \cdots + \delta_{K-1} x_{K-1} + \theta_1 z_1 + r_K \quad \theta_1 \neq 0$$

- 将 x_K 的约简型方程代入结构方程，整理得:

$$y = \alpha_0 + \alpha_1 x_1 + \cdots + \alpha_{K-1} x_{K-1} + \lambda_1 z_1 + v \quad \text{也称为} y \text{的约简型方程}$$

$$\alpha_j = \beta_j + \beta_K \delta_j \quad \lambda_1 = \beta_K \theta_1 \quad v = u + \beta_K r_K$$

- 该方程的OLS估计结果为 y 约简型方程中约简参数的估计，而非 y 的结构方程中的结构参数 β

- 有时结构参数更有意义:

- 例如: y 为平均生产率; x_K 为参加培训小时数, z_1 为培训费用

- 多元回归中的IV估计

- 参照OLS估计: $y = \mathbf{x}\boldsymbol{\beta} + u$ $\mathbf{x}$ is a $1 \times K$ vector of regressors $\mathbf{x} \equiv (x_1, x_2, \dots, x_K)$

$$y_i = \mathbf{x}_i\boldsymbol{\beta} + u_i \quad \mathbf{x}_i \text{ is } 1 \times K \text{ and } y_i \text{ is a scalar.}$$

$$\begin{aligned} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \dots - \hat{\beta}_k x_{ik}) &= 0 \\ \sum_{i=1}^n x_{i1} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \dots - \hat{\beta}_k x_{ik}) &= 0 \\ \sum_{i=1}^n x_{i2} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \dots - \hat{\beta}_k x_{ik}) &= 0 \\ &\vdots \\ \sum_{i=1}^n x_{ik} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \dots - \hat{\beta}_k x_{ik}) &= 0. \end{aligned}$$

$$\mathbf{X}_{n \times k} \equiv \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \\ \vdots \\ \mathbf{x}_n \end{bmatrix} = \begin{bmatrix} 1 & x_{12} & x_{13} & \dots & x_{1k} \\ 1 & x_{22} & x_{23} & \dots & x_{2k} \\ \vdots & & & & \\ 1 & x_{n2} & x_{n3} & \dots & x_{nk} \end{bmatrix}$$

$$\mathbf{X}'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0} \quad \hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}.$$

- IV估计中: $\mathbf{z} \equiv (z_1, z_2, \dots, z_K)$

结构方程中的变量

$$\mathbf{x} \equiv (x_1, x_2, \dots, x_K)$$

- IV估计量: $\hat{\boldsymbol{\beta}} = (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\mathbf{Y}$

$\mathbf{Z}$ and $\mathbf{X}$ are $N \times K$ data matrices and $\mathbf{Y}$ is the $N \times 1$ data vector on the y_i

- 进一步：若2个以上的变量(如 $z_k, z_{k+1} \dots$ 等)均与 y_2 相关，且均与 u_1 不相关，如何选择 y_2 的IV?

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \dots + \beta_k z_{k-1} + u_1,$$

$$y_2 = \pi_0 + \pi_1 z_1 + \dots + \pi_{k-1} z_{k-1} + \pi_k z_k + v_2,$$

- 直观上，这些变量均可作为 y_2 的IV

- 有：
$$E(z_1 u_1) = \dots = E(z_{k-1} u_1) = E(z_k u_1) = E(z_{k+1} u_1) = E(z_{k+2} u_1) = \dots = 0$$

- 于是：可得到多个不同的IV估计值

$$\sum_{i=1}^n (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1} - \dots - \hat{\beta}_{k-1} z_{i,k-1}) = 0$$

$$\sum_{i=1}^n z_{i1} (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1} - \dots - \hat{\beta}_{k-1} z_{i,k-1}) = 0$$

...

$$\sum_{i=1}^n z_{ik} (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1} - \dots - \hat{\beta}_{k-1} z_{i,k-1}) = 0$$

$$\sum_{i=1}^n z_{i,k+1} (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1} - \dots - \hat{\beta}_{k-1} z_{i,k-1}) = 0$$

...

• 无法保证同一参数的所有估计值相等(多个不同的IV估计值)，称结构方程是**过度识别**的

• 结构方程**无法识别**：找不到被排除的IV

• 解决途径：

• 尝试选择不同的IV，从拟合优度角度最终确定最佳的IV和估计

• 采用**二阶段最小二乘估计**

两阶段最小二乘

- 问：若2个以上的变量(如 z_2 和 z_3)均与 y_2 相关，且均与 u_1 不相关，如何选择 y_2 的IV？

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u_1.$$

- 答：外生变量的任何线性组合都是有效的IV，应选择与 y_2 最相关的线性组合

控制了原外生变量
的条件下

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + v_2,$$

$$E(v_2) = 0, \text{Cov}(z_1, v_2) = 0, \text{Cov}(z_2, v_2) = 0, \text{ and } \text{Cov}(z_3, v_2) = 0.$$

- 得到 y_2 的约简型方程，找到与 y_2 最相关的外生变量的线性组合作为 y_2 的IV

- y_2 的IV为: $\hat{y}_2 = \hat{\pi}_0 + \hat{\pi}_1 z_1 + \hat{\pi}_2 z_2 + \hat{\pi}_3 z_3$

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u_1.$$

- 统计显著性要求: $\pi_2 \neq 0$ or $\pi_3 \neq 0$.

- 不能同时为0, 将产生完全共线(IV与 z_1 完全相关)

- 利用F检验对 $\pi_2 = \pi_3 = 0$ 进行联合检验, 要求联合显著

- 于是:

$$\sum_{i=1}^n (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) = 0$$

$$\sum_{i=1}^n z_{i1} (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) = 0$$

$$\sum_{i=1}^n z_{i2} (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) = 0.$$

$\because E(\hat{y}_2 u_1) = 0$ 替换为

$$\sum_{i=1}^n \hat{y}_{i2} (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) = 0.$$

得到的估计量是多重工具下的IV估计量, 称为两阶段最小二乘估计量(two stage least squares estimator, TSLS, 2SLS)

- 两阶段最小二乘：以包含一个内生变量的结构方程为例

- 第1阶段：估计内生变量 y_2 的IV

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u_1.$$

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + v_2,$$

外生变量的线性组合，与 u_1 不相关

y_2^*

v_2

与 u_1 相关导致 y_2 的内生性

$$y_2 = y_2^* + v_2$$

$$\hat{y}_2 = \hat{\pi}_0 + \hat{\pi}_1 z_1 + \hat{\pi}_2 z_2 + \hat{\pi}_3 z_3$$

- 第2阶段：估计结构方程的结构参数，即：

$$y_1 = \beta_0 + \beta_1 y_2^* + \beta_2 z_1 + u_1 + \beta_1 v_2.$$

复合误差项

- 做与 y_1 对 $\hat{y}_2$ 和 z_1 的OLS回归，得到结构系数的2SLS估计

- 问题1：第2阶段的OLS估计是否是好的估计？

- 答：是。复合误差项有零均值；第一阶段得到的 $\hat{y}_2$ 与 u_1 不相关(是外生变量的线性组合)； $\hat{y}_2$ 和 v_2 不相关； z_1 和 u_1 、 v_2 都不相关

- 两阶段最小二乘：以包含一个内生变量的结构方程为例

- 第1阶段：估计内生变量 y_2 的IV

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u_1.$$

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + v_2, \quad y_2 = y_2^* + v_2 \quad \hat{y}_2 = \hat{\pi}_0 + \hat{\pi}_1 z_1 + \hat{\pi}_2 z_2 + \hat{\pi}_3 z_3$$

- 第2阶段：估计模型参数，即： $y_1 = \beta_0 + \beta_1 y_2^* + \beta_2 z_1 + u_1 + \beta_1 v_2$

- 问题2：第1阶段为什么要控制结构方程中的外生变量（如下 z_1 ）？

- 第1阶段： $y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + v_2$

- 假设： $z_1 = \alpha_0 + \alpha_1 z_2 + \alpha_2 z_3 + v_1$

- 有：
$$\begin{aligned} y_2 &= \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + v_2 \\ &= \pi_0 + \pi_1 (\alpha_0 + \alpha_1 z_2 + \alpha_2 z_3 + v_1) + \pi_2 z_2 + \pi_3 z_3 + v_2 \\ &= (\pi_0 + \pi_1 \alpha_0) + (\pi_1 \alpha_1 + \pi_2) z_2 + (\pi_1 \alpha_2 + \pi_3) z_3 + (\pi_1 v_1 + v_2) \end{aligned}$$

若 y_2 的约简型中不控制结构方程中的外生变量 z_1 ：

$$y_2 = \delta_0 + \delta_1 z_2 + \delta_2 z_3 + \epsilon_2 = \hat{y}_2 + \epsilon_2$$

- 第2阶段：
$$\begin{aligned} y_1 &= \beta_0 + \beta_1 (\hat{y}_2 + \epsilon_2) + \beta_2 z_1 + u_1 \\ &= \beta_0 + \beta_1 \hat{y}_2 + \beta_2 z_1 + (u_1 + \beta_1 \epsilon_2) \end{aligned}$$

ϵ_2 与 z_1 相关使得 z_1 失去外生性，将导致所有参数的不一致估计！

- 两阶段最小二乘注意的问题：

- 可通过第2阶段OLS估计，得到结构参数的2SLS估计
- 但应避免分步独立计算

$$y = \mathbf{x}\boldsymbol{\beta} + u$$

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u_1.$$

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + v_2,$$

$$y_2 = y_2^* + v_2$$

$$y_2^*$$

$$v_2$$

复合误差项

$$y_1 = \beta_0 + \beta_1 y_2^* + \beta_2 z_1 + u_1 + \beta_1 v_2.$$

- 原因：第2阶段OLS估计给出的方差估计量并不是2SLS的方差估计量：
 - 第2阶段回归的残差(复合误差)：
 - 2SLS的残差定义为：

$$y_i - \hat{\mathbf{x}}_i \hat{\boldsymbol{\beta}}, \quad \hat{\mathbf{x}}_i \text{ as the instruments for } \mathbf{x}_i$$

2SLS residuals $\hat{u}_i = y_i - \mathbf{x}_i \hat{\boldsymbol{\beta}}, \quad i = 1, 2, \dots, N$ x为结构方程中的所有解释变量

- 不同于第2阶段OLS回归的残差，导致显著性检验问题

- 2SLS示例 (例15.5 MROZ.WFL): 分析已婚职业女性的教育回报率
 - 因存在能力遗漏, 结构方程为:

$$\log(wage) = \beta_0 + \beta_1 educ + \beta_2 exper + \beta_3 exper^2 + u_1,$$

内生变量

外生变量

- 找educ的IV: 母亲和父亲的受教育程度与 u_1 无关, 与educ有关, 约简型方程为:

$$educ = \pi_0 + \pi_1 exper + \pi_2 exper^2 + \pi_3 motheduc + \pi_4 fatheduc + v_2,$$

- 统计显著性要求: $\pi_3 \neq 0$ or $\pi_4 \neq 0$

■ 2SLS的R实现：分析已婚职业女性的教育回报率

```
> summary(morzs_2sls<-tsls(LWAGE~EDUC+EXPER+EXPERSQ,  
+ instruments=~FATHEDUC+MOTHEDEC+EXPER+EXPERSQ,data=Data))
```

2SLS Estimates

(列出所有的外生变量)

Model Formula: LWAGE ~ EDUC + EXPER + EXPERSQ

Instruments: ~FATHEDUC + MOTHEDEC + EXPER + EXPERSQ

Residuals:

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-3.0990	-0.3196	0.0551	0.0000	0.3689	2.3490

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0481002931	0.4003280776	0.12015	0.9044195
EDUC	0.0613966299	0.0314366956	1.95302	0.0514712
EXPER	0.0441703929	0.0134324755	3.28833	0.0010918 **
EXPERSQ	-0.0008989696	0.0004016856	-2.23799	0.0257400 *

```
lm(formula = LWAGE ~ EDUC + EXPER + EXPERSQ, data = Data) ' 1
```

Residuals:

Min	1Q	Median	3Q	Max
-3.08404	-0.30627	0.04952	0.37498	2.37115

OLS估计

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.5220406	0.1986321	-2.628	0.00890 **
EDUC	0.1074896	0.0141465	7.598	1.94e-13 ***
EXPER	0.0415665	0.0131752	3.155	0.00172 **
EXPERSQ	-0.0008112	0.0003932	-2.063	0.03974 *

```
summary(morzs_iv<-ivreg(LWAGE~EDUC+EXPER+EXPERSQ  
| FATHEDUC+MOTHEDEC+EXPER+EXPERSQ,data=Data))
```

#给多个IV即为两阶段最小二乘

```
summary(morzs_iv<-ivreg(LWAGE~EDUC+EXPER+EXPERSQ  
|.-EDUC+FATHEDUC+MOTHEDEC,data=Data))
```

#简单的写法

```
. ivregress 2sls LWAGE EXPER EXPERSQ (EDUC=FATHEDUC MOTHEDEC )
```

Instrumental variables (2SLS) regression	Number of obs	=	428
	Wald chi2(3)	=	24.65
	Prob > chi2	=	0.0000
	R-squared	=	0.1357
	Root MSE	=	.67155

LWAGE	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
EDUC	.0613966	.0312895	1.96	0.050	.0000704	.1227228
EXPER	.0441704	.0133696	3.30	0.001	.0179665	.0703742
EXPERSQ	-.000899	.0003998	-2.25	0.025	-.0016826	-.0001154
_cons	.0481003	.398453	0.12	0.904	-.7328532	.8290538

Instrumented: EDUC

Instruments: EXPER EXPERSQ FATHEDUC MOTHEDEC

•2SLS中educ不显著的原因?

•2SLS的标准误为什么较大?

•如何提高EDUC的显著性? 后讲

- 2SLS估计量的标准误:

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u_1, \quad y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + v_2,$$

$$y_2 = y_2^* + v_2$$

$$y_1 = \beta_0 + \beta_1 y_2^* + \beta_2 z_1 + u_1 + \beta_1 v_2.$$

y_2^*

v_2

- 估计量的方差为：分子以2SLS残差的方差来估计

$$\frac{\sigma^2}{SST_{y_2^*} (1 - \hat{R}_{y_2^*}^2)}$$

y_2^* 的总变差

y_2^* 对结构方程中其他解释变量回归的拟合优度

- 2SLS估计量标准误较OLS大的原因： y_2^* 的总变差较 y_2 小导致方差较大
 - 多重共线性在TSLS中更加严重
 - 不良的工具变量($\pi_2 \pi_3$ 近似0)进一步加大估计量的方差
- OLS估计和2SLS估计的选择
 - 关注估计值的差异是否显著，也即关注变量是否是内生的

IV估计和2SLS估计

- 结构方程:

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u_1.$$

- 约简型方程:

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + v_2,$$

$$\pi_2 \neq 0. \quad \text{单个IV}$$

- 一阶条件方程组:

$$\sum_{i=1}^n (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) = 0$$

$$\sum_{i=1}^n z_{i1} (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) = 0$$

$$\sum_{i=1}^n \hat{z}_{i2} (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) = 0.$$

IV估计

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + v_2,$$

$$\pi_2 \neq 0 \text{ or } \pi_3 \neq 0.$$

多个IV, 结构方程过度识别

$$\sum_{i=1}^n \hat{y}_{i2} (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) = 0.$$

2SLS估计

IV估计和2SLS估计

- 当每个内生变量仅有单个IV下，2SLS等同于IV估计

- 例如：

$$y = \beta_0 + \beta_1 x + u,$$

- 第一阶段： $x = \pi_0 + \pi_1 z + v = \hat{x} + v$

- 第二阶段：

$$y = \beta_0 + \beta_1 (\hat{x} + v) + u = \beta_0 + \beta_1 \hat{x} + (\beta_1 v + u)$$

- 对第二阶段做OLS估计 (得到2SLS估计)：

$$\begin{aligned}\beta_1^{2SLS} &= \frac{\text{Cov}(y, \hat{x})}{\text{Var}(\hat{x})} = \frac{\text{Cov}(y, \pi_0 + \pi_1 z)}{\text{Var}(\pi_0 + \pi_1 z)} = \frac{\pi_1 \text{Cov}(y, z)}{\pi_1^2 \text{Var}(z)} \\ &= \frac{\text{Cov}(y, z)}{\pi_1 \text{Var}(z)} = \frac{\text{Cov}(y, z)}{\frac{\text{Cov}(x, z)}{\text{Var}(z)} \text{Var}(z)} = \frac{\text{Cov}(y, z)}{\text{Cov}(x, z)}\end{aligned}$$

IV估计

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^n (z_i - \bar{z})(x_i - \bar{x})}.$$

2SLS的深入问题

- 结构方程中变量的内生性检验
 - 对内生性变量才需要寻找IV
- 检验候选IV的工具外生性
 - 与内生变量相关(工具相关性): 容易检验
 - 与误差项不相关(工具外生性): 不易检验, 因为误差项无法观测, 如何检验?

内生性检验

- 内生性检验：检验模型中的解释变量是否是内生的

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \beta_3 z_2 + u_1,$$

- 内生性检验的必要性：
 - 若 y_2 是外生的，因2SLS估计量的标准误大于OLS，选择OLS估计量更合理，检验是必要的
- 内生性检验方法：豪斯曼 (Hausman) 法，基本想法：
 - 对比OLS和2SLS估计值，对两估计值差异的统计显著性进行检验，且相信：
 - 若 y_2 是外生的，OLS和2SLS估计差异不显著
 - 若 y_2 是内生的，OLS和2SLS估计差异显著

- 豪斯曼法实现思路 (基于回归的控制函数法):

- 对于结构方程和约简型方程

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \beta_3 z_2 + u_1,$$

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + \pi_4 z_4 + v_2.$$

- 若 y_2 是外生的, 则 y_2 与 u_1 不相关
 - 因各个 z_j 与 u_1 都不相关, y_2 与 u_1 不相关的充要条件是 v_2 与 u_1 不相关, 即:

$$u_1 = \delta_1 v_2 + e_1, \quad H_0: \delta_1 = 0$$

- 将 u_1 代回结构方程:

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \beta_3 z_2 + \delta_1 v_2 + e_1 \quad \text{假设} z \text{与} e_1 \text{不相关}$$

$$H_0: \delta_1 = 0 \quad \text{检验控制了 } y_2, z_1, z_2 \text{ 下 } v_2 \text{ 与 } y_1 \text{ 的相关性, 即与 } u_1 \text{ 的相关性}$$

- 拒绝 H_0 , 知 v_2 与 u_1 相关进而断定 y_2 具有内生性, OLS和2SLS估计差异显著
 - 因误差项无法观测只能借助残差项

内生性检验

- 豪斯曼法对单个变量内生性检验的步骤：

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \beta_3 z_2 + u_1,$$

- 第一，做 y_2 对所有外生变量(包括结构方程中的外生解释变量和被排除的外生变量)回归：

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + \pi_4 z_4 + v_2.$$

- 估计 y_2 的约简型方程得到： $\hat{v}_2$ $u_1 = \delta_1 v_2 + e_1$, $H_0: \delta_1 = 0$

- 第二，在结构方程中添加 $\hat{v}_2$ ，做OLS回归

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \beta_3 z_2 + \delta_1 \hat{v}_2 + error \quad \text{豪斯曼检验方程}$$

- 第三，利用t统计量检验： $H_0: \delta_1 = 0$

- 若 $\hat{v}_2$ 的系数与零有显著差异，则因 v_2 与 u_1 相关而断定 y_2 具有内生性，OLS和2SLS估计应差异显著(为什么?)

■ 变量内生性检验示例 (例15.7 MROZ.WFL): 分析已婚职业女性的教育回报率

■ 结构方程

$$\log(\text{wage}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{exper}^2 + u_1,$$

```
lm(formula = LWAGE ~ EDUC + EXPER + EXPERSQ, data = Data)

Residuals:
    Min       1Q   Median       3Q      Max
-3.08404 -0.30627  0.04952  0.37498  2.37115

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.5220406  0.1986321  -2.628  0.00890 **
EDUC         0.1074896  0.0141465   7.598 1.94e-13 ***
EXPER        0.0415665  0.0131752   3.155  0.00172 **
EXPERSQ      -0.0008112  0.0003932  -2.063  0.03974 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6664 on 424 degrees of freedom
Multiple R-squared:  0.1568,    Adjusted R-squared:  0.1509
F-statistic: 26.29 on 3 and 424 DF,  p-value: 1.302e-15
```

OLS估计

- 怀疑educ可能是内生变量

- 建立EDUC的约简型方程: 排除的外生变量为: mothedu、fatheduc

Analysis of Variance Table

```
Model 1: EDUC ~ EXPER + EXPERSQ
Model 2: EDUC ~ EXPER + EXPERSQ + FATHEDUC + MOTHEDEC
   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
1     425 2219.2
2     423 1758.6  2     460.64 55.4 <2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- EDUC的约简型方程中, 排除的外生变量mothedu、fatheduc联合显著

■ 变量内生性检验示例(例15.7):分析已婚职业女性的教育回报率

■ 2SLS估计:

```
ivreg(formula = LWAGE ~ EDUC + EXPER + EXPERSQ | FATHEDUC + MOTHEDUC +  
      EXPER + EXPERSQ, data = Data)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.0986	-0.3196	0.0551	0.3689	2.3493

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0481003	0.4003281	0.120	0.90442
EDUC	0.0613966	0.0314367	1.953	0.05147 .
EXPER	0.0441704	0.0134325	3.288	0.00109 **
EXPERSQ	-0.0008990	0.0004017	-2.238	0.02574 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6747 on 424 degrees of freedom
Multiple R-Squared: 0.1357, Adjusted R-squared: 0.1296
Wald test: 8.141 on 3 and 424 DF, p-value: 2.787e-05

2SLS估计

• OLS估计还是2SLS估计?

- OLS估计量的方差小于2SLS
- 估计值有差异, 需判断差异是否显著
- 进行EDUC的内生性检验

```
lm(formula = LWAGE ~ EDUC + EXPER + EXPERSQ, data = Data)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.08404	-0.30627	0.04952	0.37498	2.37115

OLS估计

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.5220406	0.1986321	-2.628	0.00890 **
EDUC	0.1074896	0.0141465	7.598	1.94e-13 ***
EXPER	0.0415665	0.0131752	3.155	0.00172 **
EXPERSQ	-0.0008112	0.0003932	-2.063	0.03974 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6664 on 424 degrees of freedom
Multiple R-squared: 0.1568, Adjusted R-squared: 0.1509
F-statistic: 26.29 on 3 and 424 DF, p-value: 1.302e-15

- 检验educ的内生性：采用豪斯曼法，计算约简型方程的残差，并加入到结构方程中做OLS回归：

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \beta_3 z_2 + u_1,$$

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + \pi_4 z_4 + v_2.$$

$$u_1 = \delta_1 v_2 + e_1, H_0: \delta_1 = 0$$

豪斯曼检验方程： $y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \beta_3 z_2 + \delta_1 v_2 + e_1$

```
lm(formula = LWAGE ~ EDUC + EXPER + EXPERSQ + b$residual, data = Data)
```

约简型方程的残差

Residuals:

	Min	1Q	Median	3Q	Max
	-3.03743	-0.30775	0.04191	0.40361	2.33303

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0481003	0.3945753	0.122	0.903033
EDUC	0.0613966	0.0309849	1.981	0.048182 *
EXPER	0.0441704	0.0132394	3.336	0.000924 ***
EXPERSQ	-0.0008990	0.0003959	-2.271	0.023672 *
b\$residual	0.0581666	0.0348073	1.671	0.095441 .

豪斯曼检验

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

- 结论：t检验表明在0.1的显著性水平下拒绝原假设，约简型方程的残差与 u_1 有适度相关，拒绝educ外生性，OLS和2SLS估计差异显著(为什么)

■ 再看豪斯曼检验：为什么若 y_2 是外生的，OLS和TSLs估计差异不显著？

```
lm(formula = LWAGE ~ EDUC + EXPER + EXPERSQ + b$residual, data = Data)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-3.03743	-0.30775	0.04191	0.40361	2.33303

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0481003	0.3945753	0.122	0.903033
EDUC	0.0613966	0.0309849	1.981	0.048182 *
EXPER	0.0441704	0.0132394	3.336	0.000924 ***
EXPERSQ	-0.0008990	0.0003959	-2.271	0.023672 *
b\$residual	0.0581666	0.0348073	1.671	0.095441 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

豪斯曼检验

```
ivreg(formula = LWAGE ~ EDUC + EXPER + EXPERSQ | FATHEDUC + MOTHEDEC +  
EXPER + EXPERSQ, data = Data)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-3.0986	-0.3196	0.0551	0.3689	2.3493

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0481003	0.4003281	0.120	0.90442
EDUC	0.0613966	0.0314367	1.953	0.05147 .
EXPER	0.0441704	0.0134325	3.288	0.00109 **
EXPERSQ	-0.0008990	0.0004017	-2.238	0.02574 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6747 on 424 degrees of freedom
Multiple R-Squared: 0.1357, Adjusted R-squared: 0.1296
Wald test: 8.141 on 3 and 424 DF, p-value: 2.787e-05

2SLS估计

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \beta_3 z_2 + u_1,$$

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + \pi_4 z_4 + v_2.$$

$$u_1 = \delta_1 v_2 + e_1, H_0: \delta_1 = 0$$

豪斯曼检验方程：

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \beta_3 z_2 + \delta_1 \hat{v}_2 + error$$

- 豪斯曼检验方程的OLS估计等于结构方程的2SLS估计：
 - 豪斯曼检验方程是在控制了 y_2 内生性下(拒绝 $\delta_1=0$)的OLS估计，等价于2SLS估计
- 对豪斯曼检验方程，若不能拒绝 $\delta_1=0$ (外生解释变量)意味：
 - 豪斯曼检验方程的OLS估计与结构方程的OLS估计没有显著差异(过度设置)

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \beta_3 z_2 + \delta_1 \hat{v}_2 + error$$

$$\tilde{y} = \tilde{\beta}_0 + \tilde{\beta}_1 x_1 \quad \hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 \quad \tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2 \delta_1 \quad \delta_1 \text{是舍弃的变量 } x_2 \text{ 对自变量 } x_1 \text{ 的回归系数}$$

- 豪斯曼法对多个变量内生性检验的步骤:

$$y_1 = \mathbf{z}_1 \boldsymbol{\delta}_1 + \mathbf{y}_2 \mathbf{a}_1 + u_1, \quad E(\mathbf{z}'_1 u_1) = \mathbf{0} \quad \mathbf{y}_2 \text{ denote a } 1 \times G_1 \text{ vector}$$

$\mathbf{z}_1$ is $1 \times L_1$ (including a constant), $\boldsymbol{\delta}_1$ is $L_1 \times 1$.

$$\mathbf{z} = (\mathbf{z}_1, \mathbf{z}_2) \text{ where } \mathbf{z}_2 \text{ is } 1 \times L_2 \text{ and } L = L_1 + L_2$$

- 计算多个约简型方程的残差并加入结构方程中

$$\mathbf{y}_2 = \mathbf{z} \boldsymbol{\Pi}_2 + \mathbf{v}_2, \text{ where } \boldsymbol{\Pi}_2 \text{ is } L \times G_1 \text{ and } \mathbf{v}_2 \text{ is the } 1 \times G_1 \text{ vector}$$

$$y_1 = \mathbf{z}_1 \boldsymbol{\delta}_1 + \mathbf{y}_2 \mathbf{a}_1 + \hat{\mathbf{v}}_2 \boldsymbol{\rho}_1 + \text{error}$$

- 采用F检验对残差系数做联合显著性检验

- 非约束模型: $y_1 = \mathbf{z}_1 \boldsymbol{\delta}_1 + \mathbf{y}_2 \mathbf{a}_1 + \hat{\mathbf{v}}_2 \boldsymbol{\rho}_1 + \text{error}$

- 约束模型: $y_1 = \mathbf{z}_1 \boldsymbol{\delta}_1 + \mathbf{y}_2 \mathbf{a}_1 + u_1, \quad F \text{ test of } H_0: \boldsymbol{\rho}_1 = \mathbf{0}$

- 采用LM统计量

- 计算约束模型的残差; 与非约束模型解释变量全体回归

$$\hat{u}_1 \text{ on } \mathbf{z}_1, \mathbf{y}_2, \hat{\mathbf{v}}_2 \quad NR_u^2 \text{ as asymptotically } \chi_{G_1}^2$$

工具外生性：过度识别约束检验

- IV是否与 u_1 不相关通常依据经济问题本身判断
 - 基本技术手段：借助过度识别约束进行检验
- 基本思想：若所有的候选IV都满足工具外生性，则2SLS残差与候选IV不相关

- 例：
$$\log(\text{wage}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{exper}^2 + u_1,$$

$$\text{educ} = \pi_0 + \pi_1 \text{exper} + \pi_2 \text{exper}^2 + \pi_3 \text{motheduc} + \pi_4 \text{fatheduc} + v_2,$$

- 若父母教育程度都是外生的且做educ的IV，则父母教育程度与结构方程的 u_1 (用2SLS残差作估计) 不相关
- 若检验表明候选IV与2SLS残差不相关，则表明候选IV具有工具外生性
 - 如何得到 u_1 的一致性估计是关键
 - 采用过度识别约束检验

- **过度识别：**工具变量个数大于内生解释变量个数
- 假设有一个内生变量 y_2 的结构方程： $y_1 = \beta_0 + \beta_1 y_2 + u_1$ 。两个工具变量 (z_1, z_2) ，检验 z_1, z_2 外生性：
 - 第一，**假设 z_1 满足外生性假设**，且只用 z_1 做工具变量
 - 得到系数的估计 $\hat{\beta}_1^{z_1}$ ，是 β_1 的一致性估计
 - 计算 $\hat{u}_1^{z_1} = y_1 - \hat{\beta}_0^{z_1} - \hat{\beta}_1^{z_1} y_2$ ，是 u_1 的一致性估计(z_1 满足外生性假设时)
 - 检验 z_2 的外生性： $\text{Cov}(z_2, \hat{u}_1^{z_1}) = 0$
 - 第二，**假设 z_2 满足外生性假设**，且只用 z_2 做工具变量
 - 得到系数的估计 $\hat{\beta}_1^{z_2}$ ，是 β_1 的一致性估计
 - 计算 $\hat{u}_1^{z_2} = y_1 - \hat{\beta}_0^{z_2} - \hat{\beta}_1^{z_2} y_2$ ，是 u_1 的一致性估计(z_2 满足外生性假设时)
 - 检验 z_1 的外生性： $\text{Cov}(z_1, \hat{u}_1^{z_2}) = 0$
 - 以上称为**过度识别约束检验**：需假设一个工具变量满足外生条件
- **注意：** z_2 未通过外生性检验的原因有二
 - z_2 不是外生的； z_1 本不满足外生性假设。**检验不通过表明至少有一个变量是内生的**
- **注意：** z_2 通过外生性检验，也可能源于对 z_1 假设的错误。**检验通过不能认为所有变量均外生**

工具外生性：过度识别约束检验

- 没有过度识别时的工具外生性检验是没有意义的
 - 例： $y_1 = \beta_1 y_2 + u_1$ ， y_2 为内生解释变量，有一个外生变量 z_1
 - 检验 z_1 的工具外生性：

$$\begin{aligned}\text{Cov}(z_1, \hat{u}_1^{z_1}) &= \text{Cov}(z_1, y_1 - \hat{\beta}_1^{z_1} y_2) \\ &= \text{Cov}(z_1, y_1) - \hat{\beta}_1^{z_1} \text{Cov}(z_1, y_2) \\ &= \text{Cov}(z_1, y_1) - \frac{\text{Cov}(z_1, y_1)}{\text{Cov}(z_1, y_2)} \text{Cov}(z_1, y_2) = 0\end{aligned}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^n (z_i - \bar{z})(x_i - \bar{x})}.$$

β_1 的 IV 估计

工具外生性：过度识别约束检验

- 过度识别约束检验的基本步骤：利用LM统计量
 - 第一，用2SLS估计结构方程，得到2SLS残差 $\hat{u}_1$.
 - 第二，将 $\hat{u}_1$ 对外生解释变量和候选IV回归，得到 R_u^2
 - 第三，候选IV与 u_1 均不相关的假设下： $NR_u^2 \overset{a}{\sim} \chi_{Q_1}^2$ Q_1 为过度识别约束个数
 - 第四，如果 NR_u^2 大于 $\chi_{Q_1}^2$ ，应拒绝原假设，认为至少部分候选IV不是外生的

$$y_1 = \mathbf{z}_1 \boldsymbol{\delta}_1 + \mathbf{y}_2 \mathbf{a}_1 + u_1 \quad \mathbf{z}_1 \text{ is } 1 \times L_1 \text{ and } \mathbf{y}_2 \text{ is } 1 \times G_1$$

$$\mathbf{z} = (\mathbf{z}_1, \mathbf{z}_2) \text{ where } \mathbf{z}_2 \text{ is } 1 \times L_2 \text{ and } L = L_1 + L_2$$

overidentified, $L_2 > G_1$

$$\hat{u}_1 \text{ on } \mathbf{z} \quad \longrightarrow \quad R_u^2 \quad NR_u^2 \overset{a}{\sim} \chi_{Q_1}^2$$

$Q_1 \equiv L_2 - G_1$ is the number of overidentifying restrictions.

■ 候选IV外生性检验示例(例15.8):
分析已婚职业女性的教育回报率

- 增加一个外生变量:MOTHEU
- 有1个过度识别约束

$$LM=428*0.0009=0.385$$

在卡方分布中很小, 不能拒绝原假设,
即不能拒绝父、母教育程度联合外生

```
> summary(morz_tsls<-tsls(LWAGE~EDUC+EXPER+EXPERSQ,
+ instruments=~FATHEDUC+MOTHEUC+EXPER+EXPERSQ,data=Data))

2SLS Estimates

Model Formula: LWAGE ~ EDUC + EXPER + EXPERSQ

Instruments: ~FATHEDUC + MOTHEUC + EXPER + EXPERSQ

Residuals:
    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-3.0986 -0.3196  0.0551  0.0000  0.3689  2.3493

      Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.0481002931  0.4003280776  0.12015 0.9044195
EDUC         0.0613966299  0.0314366956  1.95302 0.0514742 .
EXPER        0.0441703929  0.0134324755  3.28833 0.0010918 **
EXPERSQ      -0.0008989696  0.0004016856 -2.23799 0.0257400 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6747117 on 424 degrees of freedom

> summary(lm(morz_tsls$residuals~FATHEDUC+MOTHEUC+EXPER+EXPERSQ,data=Data))

Call:
lm(formula = morz_tsls$residuals ~ FATHEDUC + MOTHEUC + EXPER +
    EXPERSQ, data = Data)

Residuals:
    Min       1Q   Median       3Q      Max
-3.1012 -0.3124  0.0478  0.3602  2.3441

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.096e-02  1.413e-01   0.078   0.938
FATHEDUC     5.782e-03  1.118e-02   0.517   0.605
MOTHEUC     -6.607e-03  1.189e-02  -0.556   0.579
EXPER       -1.833e-05  1.333e-02  -0.001   0.999
EXPERSQ      7.341e-07  3.985e-04   0.002   0.999

Residual standard error: 0.6752 on 423 degrees of freedom
Multiple R-squared:  0.0008833 Adjusted R-squared:  -0.008565
F-statistic: 0.0935 on 4 and 423 DF,  p-value: 0.9845
```

■ 候选IV外生性检验示例(例15.8):分析已婚职业女性的教育回报率

- 再增加一个外生变量:HUSEDU
- 有2个过度识别约束

$$LM=428*0.0026=1.11$$

在卡方分布中也较小,不能拒绝原假设:不能拒绝父、母、丈夫教育程度联合外生

- 是否需要增加HUSEDU?

```
> summary(morzs_tsls<-tsls(LWAGE~EDUC+EXPER+EXPERSQ,
+ instruments=~HUSEDUC+FATHEDUC+MOTHEDEC+EXPER+EXPERSQ,data=Data))

2SLS Estimates

Model Formula: LWAGE ~ EDUC + EXPER + EXPERSQ

Instruments: ~HUSEDUC + FATHEDUC + MOTHEDEC + EXPER + EXPERSQ

Residuals:
    Min.   1st Qu.   Median     Mean   3rd Qu.    Max.
-3.08378 -0.32135  0.03538  0.00000  0.36934  2.35829

      Estimate   Std. Error  t value  Pr(>|t|)
(Intercept) -0.1868572257  0.2853958940 -0.65473 0.51299668
EDUC         0.0803917594  0.0217739706  3.69210 0.00025145 ***
EXPER        0.0430973210  0.0132648733  3.24898 0.00125039 **
EXPERSQ      -0.0008627965  0.0003961880 -2.17775 0.02997555 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6692975 on 424 degrees of freedom

> summary(lm(morzs_tsls$residuals~HUSEDUC+FATHEDUC+MOTHEDEC+EXPER+EXPERSQ,data=Data))

Call:
lm(formula = morzs_tsls$residuals ~ HUSEDUC + FATHEDUC + MOTHEDEC +
    EXPER + EXPERSQ, data = Data)

Residuals:
    Min       1Q   Median       3Q      Max
-3.07503 -0.32777  0.04156  0.37759  2.33622

Coefficients:
      Estimate Std. Error t value Pr(>|t|)
(Intercept)  8.606e-03  1.773e-01  0.049  0.961
HUSEDUC      6.781e-03  1.143e-02  0.593  0.553
FATHEDUC     6.734e-04  1.138e-02  0.059  0.953
MOTHEDEC    -1.039e-02  1.187e-02 -0.875  0.382
EXPER        5.603e-05  1.323e-02  0.004  0.997
EXPERSQ     -8.882e-06  3.956e-04 -0.022  0.982

Residual standard error: 0.67 on 422 degrees of freedom
Multiple R-squared: 0.002605, Adjusted R-squared: -0.009212
F-statistic: 0.2205 on 5 and 422 DF, p-value: 0.9537
```

■ 合理的过度识别可减少2SLS估计量的方差: 例15.8

```
> summary(morzs_2s1s<-tsls(LWAGE~EDUC+EXPER+EXPERSQ,
+ instruments=~FATHEDUC+MOTHEDEDUC+EXPER+EXPERSQ,data=Data))
```

2SLS Estimates

Model Formula: LWAGE ~ EDUC + EXPER + EXPERSQ

Instruments: ~FATHEDUC + MOTHEDEDUC + EXPER + EXPERSQ

Residuals:

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
	-3.0986	-0.3196	0.0551	0.0000	0.3689	2.3493

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0481002931	0.4003280776	0.12015	0.9044195
EDUC	0.0613966299	0.0314366956	1.95302	0.0514742
EXPER	0.0441703929	0.0134324755	3.28833	0.0010918
EXPERSQ	-0.0008989696	0.0004016856	-2.23799	0.0257400

$$\log(\text{wage}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{exper}^2 + u_1,$$

$$y_2 = y_2^* + v_2$$

$$y_1 = \beta_0 + \beta_1 y_2^* + \beta_2 z_1 + u_1 + \beta_1 v_2.$$

$$\frac{\sigma^2}{SST_{educ1}^* (1 - \hat{R}_{educ1}^2)}$$

$$\frac{\sigma^2}{SST_{educ2}^* (1 - \hat{R}_{educ2}^2)}$$

$$\text{educ}_1 = \pi_0 + \pi_1 \text{EXPER} + \pi_2 \text{EXPERSQ} + \pi_3 \text{MOTHEDEDUC} + \pi_4 \text{FATHEDUC} + v_1$$

$$\text{educ}_2 = \pi_0 + \pi_1 \text{EXPER} + \pi_2 \text{EXPERSQ} + \pi_3 \text{MOTHEDEDUC} + \pi_4 \text{FATHEDUC} + \pi_5 \text{HUSEDUC} + v_2$$

• 增加一个过度识别约束

• $SST_{educ2}^* > SST_{educ1}^*$, 估计量方差减少

• 若增加过度识别约束可提高待研究变量的显著性, 可引入; 但增加过多过度识别约束, 会导致2SLS严重偏误! (超出书范围)

```
> summary(morzs_2s2s<-tsls(LWAGE~EDUC+EXPER+EXPERSQ,
+ instruments=~HUSEDUC+FATHEDUC+MOTHEDEDUC+EXPER+EXPERSQ,data=Data))
```

2SLS Estimates

Model Formula: LWAGE ~ EDUC + EXPER + EXPERSQ

Instruments: ~HUSEDUC + FATHEDUC + MOTHEDEDUC + EXPER + EXPERSQ

Residuals:

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
	-3.08378	-0.32135	0.03538	0.00000	0.36934	2.35829

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.1868572257	0.2853958940	-0.65473	0.51299668
EDUC	0.0803917594	0.0217739706	3.69210	0.00025145
EXPER	0.0430973210	0.0132648733	3.24898	0.00125039
EXPERSQ	-0.0008627965	0.0003961880	-2.17775	0.02997555

再看结构方程

$$0: y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + v$$

$$1: y = \beta_0 + \beta_1 x_1 + u_1, (u_1 = \beta_2 x_2 + \beta_3 x_3 + v)$$

$$2: y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u_2, (u_2 = \beta_3 x_3 + v)$$

$$3: y = \beta_0 + \beta_1 x_1 + \beta_3 x_3 + u_3, (u_3 = \beta_2 x_2 + v)$$

- 第0个模型: (y 收入, x_1 教育程度, x_2 父母收入, x_3 身高)
 - 假设: x_1 与 x_2 相关; x_1 与 x_3 不相关; x_2 与 x_3 不相关;
 - 假设: 模型不存在自变量遗漏和测量误差, 解释变量均有外生性
- 第1个模型: x_1 为内生变量
- 第2个模型: x_1 x_2 为外生变量
- 第3个模型: x_1 为内生变量, x_3 为外生变量
 - 模型中解释变量不相关的情况较少, 结构方程更有意义的应用可体现在联立方程模型中